

The poster features a blue background with various medical and technological icons. At the top left is a large DNA double helix. To its right are icons of a computer monitor, a medical device, and a molecular structure. A central shield contains the letters 'AI'. Below the shield is a plus sign in a circle. On the left side, there is a heart with a pulse line, a molecular structure, and a computer screen displaying a bar chart. At the bottom left is a small robot on a blue platform. In the center, a doctor in a white coat and stethoscope holds a clipboard. At the bottom right, there is a line graph.

# “AI医生” 您用了吗？

——基于广州市公众认知与  
使用意愿的深度调查

智疗先锋队

## 摘要

在人工智能与医疗健康深度融合的数字健康转型浪潮下，AI 问诊、智能报告解读、辅助诊疗决策等工具正逐渐走进大众生活，不断推动医疗服务普惠化、高效化、智能化发展。但是，现在公众对 AI 医疗决策却存在高认知度与低使用率的矛盾问题，这些问题不仅制约技术发展，也对行业发展造成了瓶颈。一方面，公众普遍对 AI 医疗的诊断准确性、隐私安全与责任界定等问题存在顾虑；另一方面，不同年龄、学历及媒介素养的群体在使用数字工具和获取医疗信息的能力上存在显著差异，进一步加大了 AI 医疗技术普及推广的难度。AI 医疗企业如何吸引新用户群体、提升产品使用频次，成为行业目前需要解决的问题。同时，我国也迫切需要推动 AI 医疗工具的合理普及，让数字健康理念真正走进公众生活。

梳理文献后发现，目前学界对 AI 医疗的研究多集中于技术研发与临床应用层面，从公众视角出发、系统探究认知水平与使用意愿的实证研究相对不足。针对上述问题，由于广州市人口结构比较多元化，本研究以广州市 16 岁及以上的公众为研究对象，分析人口特征、健康焦虑、技术信任与场景需求对使用意愿的影响路径。此外，本研究运用 Python 爬虫技术对微博平台相关评论进行文本挖掘，情感分析显示公众对 AI 医疗的评价以中性为主，既认可其便捷性，也存在对可靠性与隐私安全的顾虑，这表明 AI 医疗具备一定市场基础但仍有改良空间。在问卷设计和调查中，我们采用多种抽样方案，并在预调查后优化题项，之后通过问卷发放收集包括用户基本信息、AI 医疗使用频率、影响因素偏好倾向在内的多类信息。在正式调查时，本文分了三个阶段进行总体质量控制。

在数据分析阶段，本研究先对数据进行描述性统计分析，发现受访者对 AI 医疗认知广度尚可但深度不足，仅 42.2% 的人表示有过使用经历。为了识别影响公众使用意愿的因素，本研究采用 Logistic 回归模型对多个变量进行筛选，结果显示性别、学历、收入、是否与父母同居、职业等变量会显著影响公众使用 AI 进行医疗决策的意愿，这为后续深入探究影响机理奠定了用户画像基础。在此基础上，引入神经网络模型，进一步挖掘影响用户决策的关键指标，发现平台承担决策错误的责任、AI 医疗决策代替医生的诊断能力、敏感疾病的诊断、用户对 AI 的接受能力、AI 解读报告的能力是重要性最高的五项因素，从而揭示了信任属性与场景属性在用户决策中的核心地位。为探究上述因素之间的内在作用机制，本研究构建结构方程模型，验证了信任属性、宣传属性、基础属性、用户属性和场景属性对使用意愿的显著影响，并发现其他四个属性均通过影响场景属性间接作用于使用意愿。最后回到用户本身，运用 K-means 聚类分析对用户群体进行细分，识别出高学历依赖型、高收入家庭支柱人群、高学历独立独居型、家庭核心

型家长四类典型群体，其中高学历独立独居型对信任属性、场景属性、基础属性的重视程度均达到了 3.4 分（满分 5 分）以上，远高于其他群体，且自身数字素养较强，是市场推广中值得优先培育的核心潜在用户。通过上述层层递进的实证分析，本研究系统揭示了公众对 AI 医疗的认知现状、影响机理与用户分型特征。

基于以上研究结论，广州市公众对 AI 医疗整体持支持但审慎态度，政府推荐是影响使用意愿的一个关键因素。用户使用意愿受信任、场景、基础、用户、宣传五重属性共同驱动，其中场景属性发挥核心中介作用。用户群体呈现显著分化，高学历独立独居型对信任、场景、基础属性的重视程度远高于其他群体，是值得优先培育的核心潜在用户。建议充分发挥政府权威引导作用，聚焦场景化应用，实施差异化产品策略，推动 AI 医疗从技术可行向群众可信跨越。

**关键词：**AI 医疗决策；广州市公众；结构方程模型；Logistic 回归；K-means 聚类；神经网络模型



## 目录

|                                         |    |
|-----------------------------------------|----|
| 一、绪论.....                               | 1  |
| (一) 研究背景.....                           | 1  |
| (二) 文献综述.....                           | 1  |
| (三) 研究目的和意义.....                        | 5  |
| (四) 研究思路和内容.....                        | 6  |
| (五) 研究方法.....                           | 6  |
| (六) 研究创新点.....                          | 8  |
| 二、基于政策层面与文本挖掘的 AI 医疗发展现状分析.....         | 9  |
| (一) AI 技术发展情况.....                      | 9  |
| (二) 政府对 AI 医疗的监管和政策制定情况.....            | 10 |
| (三) AI 医疗市场化分析.....                     | 11 |
| (四) 基于 PYTHON 网络数据爬取与文本挖掘分析.....        | 13 |
| 三、调查方案设计与实施.....                        | 15 |
| (一) 调查对象.....                           | 15 |
| (二) 调查问卷的设计.....                        | 15 |
| (三) 抽样方案设计.....                         | 16 |
| (四) 样本量的确定.....                         | 19 |
| (五) 数据质量控制.....                         | 20 |
| (六) 信效度检验.....                          | 21 |
| (七) 调查组织工作和实施过程.....                    | 22 |
| 四、描述性统计分析.....                          | 24 |
| (一) 受访者基本信息.....                        | 24 |
| (二) 受访者对 AI 医疗的认知与使用现状.....             | 25 |
| (三) 受访者对 AI 医疗的内在态度.....                | 26 |
| (四) 受访者对 AI 医疗当前和未来的使用意愿对比.....         | 28 |
| 五、基于 Logistic 回归模型的 AI 医疗用户特征分析.....    | 30 |
| (一) 二元 Logistic 回归模型的构建.....            | 30 |
| (二) 模型结果分析.....                         | 35 |
| 六、基于神经网络模型的公众对 AI 医疗使用意愿影响因素分析.....     | 37 |
| (一) 模型概述.....                           | 37 |
| (二) 模型建立.....                           | 38 |
| (三) 模型评价与检验.....                        | 39 |
| (四) 不同因素对公众接受使用 AI 大模型的影响分析.....        | 41 |
| 七、基于结构方程模型的影响公众使用 AI 医疗因素的内在作用机制分析..... | 43 |
| (一) 模型选择.....                           | 43 |
| (二) 模型构建与运行结果.....                      | 43 |
| (三) 模型分析结果解释与发展.....                    | 47 |
| 八、基于 K-means 的用户特征分析及潜在用户挖掘.....        | 48 |
| (一) K-means 聚类原理.....                   | 48 |
| (二) 最佳聚类数 K 的确定.....                    | 48 |
| (三) 人群特征画像.....                         | 50 |

|                                |    |
|--------------------------------|----|
| (四) 人群分群与 AI 医疗使用意愿的关联性分析..... | 50 |
| (五) 不同人群 AI 医疗决策使用意愿差异分析.....  | 51 |
| (六) 不同用户群体对五维属性的重视程度.....      | 52 |
| (七) 最具潜力的核心用户群体.....           | 53 |
| 九、结论与展望.....                   | 54 |
| (一) 结论.....                    | 54 |
| (二) 对策建议.....                  | 55 |
| (三) 展望.....                    | 55 |
| 参考文献.....                      | 57 |
| 附录.....                        | 59 |
| 附录一: 问卷内容.....                 | 59 |
| 附录二: 专家访谈.....                 | 69 |
| (一) 刘献标医生的百度健康认证: .....        | 69 |
| (二) 关于刘献标医生的专家访谈.....          | 69 |
| 附录三: 线下调查过程.....               | 72 |
| 附录四: 核心代码解释.....               | 74 |
| 附录五: 不同人群对各个指标的平均重视度得分.....    | 89 |
| 附录六: AI 使用情况说明.....            | 92 |

## 图目录

|      |                           |    |
|------|---------------------------|----|
| 图 1  | 研究框架图                     | 6  |
| 图 2  | 蚂蚁阿福展示图                   | 12 |
| 图 3  | AI 医疗博文词频分析结果图            | 14 |
| 图 4  | 情感词频分析结果图                 | 14 |
| 图 5  | 团队分工图                     | 23 |
| 图 6  | 调查进度图                     | 23 |
| 图 7  | 受访者性别比例                   | 24 |
| 图 8  | 受访者年龄占比                   | 24 |
| 图 9  | 受访者（人均）月可支配收入占比           | 25 |
| 图 10 | 受访者对 AI 医疗的认知情况图          | 26 |
| 图 11 | 受访者对 AI 医疗的了解程度图          | 26 |
| 图 12 | 受访者是否使用过 AI 大模型进行医疗决策     | 26 |
| 图 13 | 受访者对 AI 医疗当前和未来的使用意愿得分对比图 | 29 |
| 图 14 | 未来使用意愿提升的用户数量统计图          | 29 |
| 图 15 | ROC 曲线图                   | 32 |
| 图 16 | 剔除年龄变量后 ROC 曲线图           | 34 |
| 图 17 | 神经网络模型结构                  | 39 |
| 图 18 | 训练集分类正确率                  | 40 |
| 图 19 | 测试集分类正确集                  | 40 |
| 图 20 | 训练集 ROC 曲线                | 41 |
| 图 21 | 验证集 ROC 曲线                | 41 |
| 图 22 | AI 大模型使用意愿影响因素重要性排序       | 41 |
| 图 23 | 结构方程模型图                   | 44 |
| 图 24 | 轮廓系数图                     | 49 |
| 图 25 | CH 分数图                    | 49 |
| 图 26 | 样本 PCA 二维分布散点图            | 49 |
| 图 27 | 人群分类结果图                   | 49 |
| 图 28 | 四类人群基础属性雷达图               | 50 |
| 图 29 | 不同人群 AI 医疗决策使用意愿占比        | 51 |
| 图 30 | 不同人群在 AI 大模型各属性上的平均分对比    | 52 |

## 表目录

|      |                                      |    |
|------|--------------------------------------|----|
| 表 1  | 国内政策表 .....                          | 10 |
| 表 2  | 情感倾向分布表 .....                        | 14 |
| 表 3  | 情感分析统计结果表 .....                      | 14 |
| 表 4  | 调查问卷主体部分 .....                       | 16 |
| 表 5  | 第七次人口普查——广州市辖区人口数据 .....             | 17 |
| 表 6  | 第一阶段抽样表 .....                        | 17 |
| 表 7  | 第二阶段抽样结果 .....                       | 18 |
| 表 8  | 样本框设定表 .....                         | 18 |
| 表 9  | 各变量信度分析结果 .....                      | 21 |
| 表 10 | KMO 和巴特利特检验结果 .....                  | 22 |
| 表 11 | 正式调查信度检验结果表 .....                    | 22 |
| 表 12 | 正式调查 KMO 和巴特利特检验结果 .....             | 22 |
| 表 13 | AI 大模型用户属性对使用意愿影响的平均值（含标准误差）统计 ..... | 25 |
| 表 14 | AI 大模型信任属性对使用意愿影响的平均值（含标准误差）统计 ..... | 27 |
| 表 15 | AI 大模型宣传属性对使用意愿影响的平均值（含标准误差）统计 ..... | 27 |
| 表 16 | AI 大模型场景属性对使用意愿影响的平均值（含标准误差）统计 ..... | 28 |
| 表 17 | AI 大模型基础属性对使用意愿影响的平均值（含标准误差）统计 ..... | 28 |
| 表 18 | 用户特征变量定义表 .....                      | 31 |
| 表 19 | 二元 Logistic 模型回归结果 .....             | 32 |
| 表 20 | 剔除年龄变量后二元 Logistic 模型回归结果 .....      | 33 |
| 表 21 | 单一变量 AUC 结果 .....                    | 34 |
| 表 22 | 似然比卡方检验结果 .....                      | 35 |
| 表 23 | 公众对使用 AI 大模型进行医疗决策的影响因素 .....        | 38 |
| 表 24 | 指标路径系数结果 .....                       | 45 |
| 表 25 | 结构模型路径系数估计结果 .....                   | 46 |
| 表 26 | 结构方程模型拟合优度结果 .....                   | 47 |
| 表 27 | 迭代历史结果 .....                         | 49 |
| 表 28 | 卡方独立性检验结果 .....                      | 50 |



## 一、绪论

### （一）研究背景

目前，以人工智能（AI）为代表的新一代信息技术正加速与医疗健康产业深度融合。从 AlphaGo 战胜人类棋手再到 ChatGPT 的横空出世，AI 技术的突破使得机器具备了类人的推理与对话能力。国家卫生健康委联合国家中医药局、国家疾控局印发的《“十四五”全民健康信息化规划》明确提出，要加快医疗领域数字化转型，推动人工智能辅助诊断的广泛应用。

尽管 AI 医疗技术在影像识别、病理筛查等领域的准确率已超越人类专家，但在实际推广中却面临着“叫好不叫座”的尴尬局面。2025 年，国家层面出台《关于促进和规范“人工智能+医疗卫生”应用发展的实施意见》，明确提出“人工智能赋能而不替代”的总体定位，在各地医院得到了严格贯彻。例如，湖南省医保局发布通知明确禁止使用 AI 自动生成处方；北京则禁用 AI 自动生成处方，并成立了互联网诊疗监管平台。这些规定与国家卫健委此前发布的《互联网诊疗监管细则（试行）》一脉相承，其中明确规定“人工智能不得替代医师本人提供诊疗服务”。这更加强了公众对 AI 医疗的不可信度，同时“误诊责任不清”、“缺乏人文关怀”和“隐私泄露风险”是其主要的顾虑。

在“健康中国”战略背景下，如何跨越技术与人性之间的鸿沟，提升公众对 AI 医生的信任度，成为亟待解决的关键问题。因此，本研究旨在深入剖析公众对 AI 医生的认知与使用意愿，为 AI 医疗的普及提供一定的理论依据与实践指导。

### （二）文献综述

#### 1. AI 医疗的公众认知与信任构建机制

随着人工智能技术在医疗领域的深度渗透，公众认知与社会信任已不再仅仅是技术应用的背景变量，而是决定其能否顺利落地与规模化推广的关键前置变量。现有研究指出，公众对 AI 医疗的认知呈现出“技术乐观”与“风险规避”并存的二元悖论特征：一方面期待其提升诊疗效率与可及性，另一方面对算法黑箱、数据隐私及伦理合规性抱有深层疑虑。这种认知矛盾在老年群体及低数字素养人群中尤为显著，直接推高了技术接受的门槛<sup>[1]</sup>。

在这一认知背景下，信任作为连接公众态度与实际使用行为的核心中介变量，其构建机制呈现出显著的多维性与动态性。刘伶俐等（2019）的研究证实，公众对 AI 医疗的信任主要源于三个维度：对算法准确性的能力信任、对数据隐私保



护的制度信任以及对伦理合规的道德信任<sup>[2]</sup>。然而，徐志杰等（2017）的调查揭示了一个严峻现实：尽管用户对在线医疗服务的隐私敏感性极高，但安全认知的匮乏导致信任基础脆弱，极易因信息不对称而动摇<sup>[3]</sup>。更为关键的是，AI 医疗面临独特的“信任不对称效应”：相较于人类医生的失误，公众对 AI “幻觉”或误诊的容忍度极低，信任崩塌速度显著加快<sup>[4]</sup>。这意味着 AI 系统需具备远超人类的准确性标准，方能获得同等水平的社会信任。

针对这一困境，学界提出了“情境化治理”与“人机协同”的破局路径。雷禹和胡圆圆（2026）指出，对于 AI 的隐私担忧需从抽象的“隐私悖论”转向具体的场景权衡，通过透明的告知机制与严格的权限管控重建用户信心<sup>[5]</sup>。郑艺和林仲轩（2025）的实证研究发现，信源身份显著调节信任水平：在低风险健康情境下，“医生+AI”的协同模式比单一 AI 信源更能激发用户的采纳意图，这表明人类医生的背书是缓解公众焦虑、提升信任度的关键杠杆<sup>[6]</sup>。此外，徐汉辉（2020）强调，技术可信度必须与制度可信度双重构建，完善的监管框架与行业标准能显著降低用户的不确定性感知，使有明确监管背书的 AI 产品接受度提升 30% 以上<sup>[7]</sup>。

## 2. 健康焦虑驱动下的用户行为与场景适配

在现代社会快节奏与高压力的生活背景下，健康焦虑已成为驱动公众主动寻求 AI 医疗服务的关键心理动机。研究表明，健康焦虑水平与在线健康信息搜索行为呈显著正相关，特别是在优质医疗资源稀缺的背景下，焦虑感促使公众转向便捷、低成本的 AI 辅助工具以获取即时反馈与心理慰藉。邓婕（2024）指出，这种需求爆发推动了“AI+医疗”的快速发展，但用户行为呈现出明显的分层与场景化特征<sup>[8]</sup>。

在用户分层方面，年轻群体倾向于将 AI 作为高效的健康管理工具，关注响应速度与交互体验；而中老年及慢性病患者更看重权威性与准确性，偏好有医疗机构背书的服务。家庭健康责任亦是重要变量，承担家庭照护角色的用户更倾向于利用 AI 进行初步筛查与健康监测，以缓解照护压力<sup>[9]</sup>。

场景适配度是决定用户持续使用意愿的核心因素。严雪华等（2024）基于 ChatGPT 的分析表明，公众对 AI 在“轻问诊”、“健康咨询”、“慢病管理”等低风险场景的接受度较高，而在“重症诊断”、“手术决策”等高风险领域则持审慎保留态度<sup>[10]</sup>。顾锡新（2025）进一步指出，试图打造“全能型”AI 不仅不切实际，反而可能因过度承诺导致期望落空，进而损害信任<sup>[11]</sup>。因此，明确场景边界至关重要：在症状初筛、用药指导、康复随访等非核心诊疗环节，AI 可发挥主导作用；而在复杂临床判断中，应严格界定其辅助定位，避免引发公众对

技术越界的恐慌<sup>[12]</sup>。傅苏颖（2023）与周姝芸等（2026）的研究均强调，精准识别不同场景下的用户痛点（如夜间突发不适时的即时响应、日常保健中的长期陪伴），是提升 AI 医疗服务渗透率的关键<sup>[13]</sup>。

### 3. AI 医疗使用意愿的影响因素与群体差异

除了认知、信任与具体行为场景，公众对 AI 医疗的“使用意愿”是其技术落地的最终落脚点。现有研究普遍基于或拓展技术接受模型，探讨影响使用意愿的关键前因。感知有用性与感知易用性仍是核心变量，但在医疗语境下被赋予了更丰富的内涵：感知有用性不仅关乎效率提升，更与感知诊断准确性、健康结果改善直接挂钩；感知易用性则与交互界面的友好度、健康信息的可读性密切相关。然而，技术属性并非唯一决定因素。综合模型指出，信任是连接技术感知与使用意愿的核心中介，而风险感知（尤其是对误诊、数据泄露的担忧）则构成显著的负向抑制<sup>[14]</sup>。此外，主观规范（如家人、医生的推荐）和感知行为控制（如自我效能感）也在不同用户群体中发挥重要调节作用，表明社会影响与个人能力是推动或阻碍采纳的关键情境因素<sup>[15]</sup>。值得注意的是，使用意愿存在显著的群体异质性。年轻、高数字素养的群体对创新尝试更开放，其使用意愿更易受感知有用性和社会潮流驱动；而老年、慢性病患者等核心需求群体，其意愿更依赖于对系统可靠性的稳固信任以及清晰的收益—风险比。健康焦虑在此刻呈现出双刃剑效应：适度焦虑可驱动初步尝试，但过高的焦虑可能使患者对 AI 的建议产生过度依赖或相反的不信任，反而抑制理性使用意愿的形成<sup>[16]</sup>。因此，针对不同人群的动机与障碍进行精准干预，是提升整体使用意愿的必要路径。

进一步的研究关注持续使用意愿的维系。公众对 AI 医疗的接受并非一次性决策，而是基于初次使用体验的动态评估过程。用户体验满意度、感知价值以及使用习惯的形成，是推动用户从“尝试”转向“依赖”的关键<sup>[17]</sup>。若初期体验未能满足甚至背离预期，将导致信任迅速流失与使用中断。此外，系统的迭代优化能力、与线下医疗服务的无缝衔接度，也深刻影响着用户的长期粘性。这意味着，构建正向的使用反馈循环至关重要：通过确保核心场景下的可靠表现、提供人性化的交互与教育支持，并在使用过程中不断强化用户的控制感与获得感，才能将初步的使用意愿转化为稳固的使用习惯，最终实现 AI 医疗服务的生态化融入<sup>[18]</sup>。

### 4. 研究评述

#### （1）研究现状

当前学界围绕 AI 医疗的公众使用意愿已构建了较为完善的理论框架。在信任机制方面，学者们基于技术接受模型（TAM）等经典理论，验证了感知有用性、易用性及信任对使用意愿的正向影响，并深入探讨了隐私悖论与伦理困境等



深层次问题<sup>[5]</sup>。

近年来，随着生成式 AI 技术的突破性进展，AI 医疗的应用形态发生了深刻变革。以 MedMO 为代表的多模态大语言模型在医学影像诊断领域的应用，显著提升了 AI 系统的专业解释能力与人机交互的自然度，使得 AI 从单纯的“辅助工具”逐渐向“智能伙伴”转变<sup>[19]</sup>。这种技术形态的进化不仅改变了公众对 AI 能力边界的认知，也对传统的信任构建机制提出了挑战——当 AI 能够以类人际交互方式提供健康建议时，公众对其专业性与情感支持的期待将同步提升。

与此同时，技术发展的重心正从单纯的“能力竞赛”向“可用性进化”转移，这一趋势使得用户操作体验成为影响 AI 医疗普及的关键变量。当前的行业实践表明，模型轻量化与边缘 AI 技术的成熟，使得 AI 医疗设备正从大型医疗机构走向家庭与个人终端。这种应用场景的下沉意味着用户与 AI 的接触点将极大丰富，从偶尔的线上问诊转变为日常的健康管理陪伴<sup>[20]</sup>。在此背景下，公众对 AI 的认知将不再局限于抽象的技术概念，而是更多地建立在具体的使用体验之上，操作的便捷性、反馈的及时性以及交互的容错性将成为影响公众使用意愿的新的敏感指标。此外，具身智能与人形机器人的发展虽然主要集中在工业与服务领域，但其“物理化身”的概念也为医疗 AI 提供了新的想象空间，公众对于 AI 的看法从“虚拟助手”转变为“实体护理者”，这将成为未来研究不可忽视的新维度<sup>[21]</sup>。

## （2）研究缺口与切入点

尽管现有研究丰硕，但在以下方面仍存在局限，因此构成了本研究的切入点：

**第一，信任测量的颗粒度不足。**多数研究将信任视为单维构念，缺乏对“能力—诚信—善意”多维结构的细化拆解，尤其忽视了生成式 AI 特有的“幻觉”风险对信任的动态侵蚀机制<sup>[4]</sup>。本研究将引入信任量表，重点考察“平台审核和追责机制”与“AI 医疗诊断能力”对重建信任的具体效应。

**第二，场景化研究的微观刻画缺失。**既有研究多停留在宏观场景分类，缺乏对具体微场景下用户心理阈值与接受边界的精细测绘<sup>[10]</sup>。本研究将细化场景维度，旨在识别 AI 医疗的“黄金切入场景”与“信任红线场景”。

**第三，用户操作能力的“技能鸿沟”被忽视。**现有研究多假设用户具备基本的数字素养，能够正确操作 AI 设备，却忽视了“想用”与“会用”之间的巨大断层。事实上，用户是否能够正确使用 AI 设备直接决定了技术的实际效用与安全边界。许多潜在用户尤其是老年人，因缺乏必要的操作技能而陷入“技术无助”状态，导致设备闲置或误用。本研究将引入“用户的使用 AI 医疗设备的能力”这一变量，评估用户技能水平对 AI 医疗使用意愿的制约作用。



综上所述，本研究拟在现有理论基础上，通过细化信任维度、深耕微观场景及关注用户操作技能鸿沟，弥补现有研究缺口，为提升我国公众对 AI 医疗的认知水平与使用意愿提供更具操作性的理论支撑与实践指引。

### （三）研究目的和意义

#### 1.研究目的

本研究立足于“健康中国 2030”与人工智能技术深度融合的时代背景，旨在破解当前 AI 医疗面临的“技术高歌猛进，公众审慎观望”困境。具体目的有：

（1）**全景式描绘认知图谱：**通过大规模实证调查，系统梳理公众对 AI 医生在诊断准确性、隐私保护、伦理责任及人文关怀等方面的认知现状，精准识别阻碍其普及的“信任赤字”核心痛点。

（2）**深度解析场景化接受阈值：**突破将 AI 医疗视为单一整体的传统视角，引入“场景属性”变量。通过细分“轻问诊、慢病管理、急重症初筛”等具体情境，量化分析公众在不同风险等级下的接受意愿差异，明确 AI 医疗的“黄金应用场景”与“禁区”。

（3）**构建多维驱动机理模型：**基于 Logistic 回归与结构方程模型，结合 K-means 聚类与神经网络分析，实证检验“个人特征—健康焦虑—技术信任—社会影响”等多维因子对公众使用意愿的作用路径与影响权重。

（4）**提出差异化治理与推广策略：**基于实证结论，针对政府监管、医疗机构服务优化情形，提出具有针对性的对策建议，旨在构建“人机协同”的新型医疗生态，助力 AI 医疗从“技术可用”迈向“公众可信”。

#### 2.研究意义

##### （1）理论意义

填补本土化微观实证研究的空白：针对国内现有研究，多集中于技术实现或宏观政策，反而缺乏微观心理机制探讨的现状，因此本研究构建中国公众对 AI 医生认知的基础数据库，为本土化 AI 医疗使用意愿研究提供了一定的实证支撑。

##### （2）现实意义

**第一，响应国家战略，缓解医疗供需矛盾。**在医疗资源分布不均、优质资源紧缺的背景条件下，本研究有助于在一定程度上消除公众对 AI 技术的误解与恐惧，提升数字医疗服务的渗透率，从而推动优质医疗资源的普惠化，助力“健康中国”战略的数字化实施。

第二，赋能行业发展，优化产品与监管。研究结果能为 AI 医疗企业提供较为精确的市场画像，为其进行场景化产品设计与精准营销提供一定思路；同时，为政府完善“人工智能赋能而不替代”的监管政策提供科学依据，在鼓励技术创新与保障公众权益之间寻找最佳平衡点。

#### （四）研究思路和内容

本研究遵循“问题提出—理论构建—实证检验—对策建议”的逻辑主线展开，首先通过系统梳理相关文献构建理论模型，在此基础上设计研究问卷并开展数据收集工作，进而运用 Logistic 回归、结构方程模型等统计分析方法对研究假设进行实证检验，最终结合检验结果提出提升公众对 AI 医疗技术使用意愿的具体策略。据此，本项目小组搭建了如图 1 所示研究框架。




图 1 研究框架图

#### （五）研究方法

##### 1. 文献研究法

在确定研究主题后，我们首先查阅了大量有关 AI 医疗、智能医生、公众健康使用意愿的国内外学术文献、新闻报道与行业研究报告，全面、深入地了解当

前 AI 医生的发展现状、技术应用场景、社会接受度与行业趋势。在把握我国人工智能医疗行业整体发展背景与市场环境的基础上，聚焦公众对 AI 医生的认知水平、信任程度、使用意愿及关键影响因素，梳理现有研究的不足与空白，明确本研究的切入点，为我们下一步开展实地调查、设计问卷、进行定性分析与定量建模奠定坚实的理论基础与现实依据。

## 2.调查法

调查法是科学研究中最基础、最常用的方法之一，它可以帮助我们有针对性地、有系统、有计划地搜集研究对象的真实信息，保证研究结论来源于实际、立足于现实。本研究综合利用**问卷调查、文本数据挖掘、实地调查、专家访谈**等多种调查手段，采用线上发放与线下发放相结合、大范围抽样与针对性补充相结合的方式，广泛收集公众关于 AI 医生的认知情况、使用经历、信任感知、场景偏好、接受意愿及影响因素等相关信息。同时结合网络舆情文本、临床医生专业意见与现实医疗场景特征进行综合分析，确保数据来源多元、信息全面可靠，最终形成关于 AI 医疗普及与公众使用意愿提升的针对性建议。

## 3.定性分析法

定性分析是对研究对象进行“质”的层面分析，旨在挖掘数据背后的逻辑、特征与规律。本研究采用**归纳分析**、内容分析与比较分析相结合的方式，对回收的有效问卷、临床医生访谈记录以及网络文本挖掘数据进行统一整理、清洗、编码与分类归纳，按照人口统计特征、AI 医生认知现状、信任机制、场景适配性、社会影响因素及使用意愿等维度对信息进行系统梳理与深度解读。同时通过**横向比较与因果分析**，对比不同年龄、职业、学历、健康状况群体在态度与行为上的差异，精准识别公众在使用 AI 医生过程中的核心痛点、真实顾虑与潜在需求，探究影响其接受意愿与决策行为的关键动因，为优化 AI 医疗服务模式、开拓智慧医疗市场提供一定参考。

## 4.定量分析法

定量分析可以使人们对研究对象的认识更加精确、客观、具有说服力。本研究一方面对调查数据进行**描述性统计**，计算变量的均值、标准差、频数与占比，并结合柱状图、饼图、交叉列联表等可视化方式直观呈现样本整体分布特征与群体差异，帮助我们宏观把握公众对 AI 医生的认知与接受现状；另一方面综合运用**Logistic 回归分析、结构方程模型（SEM）、K-means 聚类分析、神经网络模型**等方法对数据进行深度挖掘。通过 Logistic 回归识别关键影响因素，通过 SEM 解析复杂影响路径，通过 K-means 聚类实现用户群体细分，再通过神经网络捕捉变量间的非线性关系与交互效应，从多维度、多层次揭示 AI 医生接受意



愿的形成机制，全面提升研究结果的科学性、精确性与解释力。

## 5.系统分析法

现有研究普遍存在视角单一、内容碎片化等问题，往往仅从技术、用户或市场某一方面展开分析，缺乏整体性与系统性。本研究坚持系统思维，整合运用**多种调查方法与分析工具**，系统分析公众认知、信任机制、场景适配、技术感知等**多方面问题**，研究内容横跨医学、信息科学、心理学等多个学科领域，能够更加全面、深刻地揭示 AI 医生使用意愿的内在逻辑，从理论层面完善公众技术接受模型，从实践层面为医疗机构、企业及政府部门提供一定的系统决策支撑。

## （六）研究创新点

本文的创新点主要体现在以下三个方面：

### 1.构建“信任-场景-功能-宣传-用户”的五维整合分析框架

传统研究多聚焦于技术接受度或使用意图的孤立考察，而本研究超越了传统对 AI 医疗决策的单维度分析框架构建了一个整合性的“信任-场景-功能-宣传-用户”**五维分析模型**。该模型不仅系统解构了用户对 AI 医疗的多维信任结构，还深入分析了场景化使用偏好、分层级功能诉求、多元化宣传渠道，并最终将这些维度与用户画像特征进行动态关联。为设计更具人性化、适应性与推广性的 AI 医疗系统提供了兼具理论深度与实践指导价值的完整分析框架。

### 2.采用用户画像与使用意愿分析的综合研究方法

本文综合运用描述性统计分析、Logistics 回归、结构方程模型、K-means 聚类和神经网络等多种研究方法，形成了“定量分析+模型构建+聚类挖掘”的多维分析体系。比如，通过结构方程模型探究用户使用意愿的影响机制，运用神经网络挖掘影响用户使用意愿的因素的重要程度，借助 K-means 聚类精准识别出高学历依赖型、高收入家庭支柱型、高学历独立独居型以及家庭核心型家长这四类具有**显著差异的用户群体**，实现了研究方法的创新性融合与互补验证，为 AI 医疗用户研究提供了可复用的分析范式。

### 3.挖掘不同用户群体的差异化需求与产品设计启示

本文在内容上实现了从宏观影响到群体分化的深度拓展。基于聚类分析识别出四类典型用户群体，并深入剖析了其在五维属性这些方面的差异化偏好。这一发现为 AI 医疗产品的差异化设计提供了精准依据，揭示了“千人千面”的用户需求本质。

## 二、基于政策层面与文本挖掘的 AI 医疗发展现状分析

近年来，随着人工智能技术与医疗健康领域的深度融合，AI 医疗已从早期技术试点迈入规模化落地阶段，而“AI 医生”作为 AI 医疗最贴近公众的核心应用形态，凭借辅助诊断、健康管理等多元功能，逐步渗透到基层诊疗、互联网医疗、公立医院日常运营等多个场景。当前我国 AI 医疗行业呈现“技术快速迭代、政策规范引领、市场稳步扩张”的发展态势，但也存在技术落地与临床需求适配不足、监管边界有待细化、市场化推广与公众认知脱节等现实问题。全面梳理 AI 医疗的技术、政策与市场化现状，既能清晰界定“AI 医生”的实际应用边界与能力水平，也能为后续开展公众认知与使用意愿调查奠定坚实的行业现实基础。

### （一）AI 技术发展情况

当前 AI 医疗技术已完成从单一功能辅助向多模态综合诊疗的升级，底层算法、算力支撑与数据积累的三重突破推动“AI 医生”从概念化产品转变为可落地的临床辅助工具。

#### 1. 核心技术迭代

多模态医疗大模型成为 AI 医生发展的核心引擎，彻底改变了早期单一影像识别、文本处理的局限。2025-2026 年，国内百度灵医大模型、腾讯觅影、阿里健康医疗大模型等专用医疗 AI 模型<sup>[6]</sup>持续升级，整合了千万级电子病历、数千份临床诊疗指南与海量专科医学文献，在常见慢病、呼吸道疾病、骨科等领域的辅助诊断准确率大幅提升。同时，自然语言处理（NLP）技术的成熟让 AI 医生具备了基础的医患沟通能力，解决了基层医疗机构医患沟通效率低、随访人力不足的痛点；计算机视觉技术则实现了医学影像的快速筛查，大幅提升了基层医疗机构的诊断效率。此外，联邦学习、隐私计算等技术的应用，有效破解了医疗数据隐私保护与模型训练数据需求的矛盾，让 AI 模型可在不转移原始医疗数据的前提下完成迭代优化，为 AI 医生的规模化推广扫清了数据层面的障碍。

#### 2. 应用场景落地

AI 医生的技术应用已形成“基层普惠、专科深耕、全流程辅助”的格局，核心聚焦三大场景：①基层医疗机构辅助诊疗。②公立医院专科辅助。③互联网医疗与居家健康管理。但从技术能力边界来看，当前 AI 医生仍存在明显短板：一是专科化差异显著，在疑难杂症、罕见病、多并发症合并病症的诊断上准确率较低；二是算法“黑箱”问题尚未完全解决，部分诊断结果缺乏可解释性。

## （二）政府对 AI 医疗的监管和政策制定情况

### 1. 国家层面顶层设计持续完善

我国对 AI 医疗行业的监管始终坚持“鼓励创新与规范发展并重”的原则，针对 AI 医生等新兴应用，逐步构建起“顶层设计+分类监管+伦理规范+地方细化”的全方位政策体系。如表 1 所示，2024-2026 年初密集出台多项核心政策，为 AI 医疗与 AI 医生发展划定清晰框架。

表 1 国内政策表

| 发布时间           | 发布单位                      | 政策名称                               | 主要内容                                                                                          |
|----------------|---------------------------|------------------------------------|-----------------------------------------------------------------------------------------------|
| 2019 年<br>7 月  | 国务院                       | 《健康中国行动（2019-2030 年）》              | 倡导健康生活方式，为后续 AI 医疗在健康管理等领域的应用奠定了政策基础。                                                         |
| 2022 年<br>3 月  | 国家药品监督管理局、医疗器械技术审评中心      | 《人工智能医疗器械注册审查指导原则》                 | 明确 AI 医疗器械的注册申报要求和技术审评规范，将 AI 辅助类产品纳入三类医疗器械管理。                                                |
| 2022 年<br>7 月  | 科技部、国家发展改革委、工业和信息化部等六部门   | 《关于加快场景创新以人工智能高水平应用促进经济高质量发展的指导意见》 | 在医疗领域积极探索医疗影像智能辅助诊断、临床诊疗辅助决策支持、医用机器人以及互联网医院等场景。                                               |
| 2022 年<br>11 月 | 国家卫生健康委、国家中医药局、国家疾控局      | 《“十四五”全民健康信息化规划》                   | 促进医学人工智能应用试点，开展医学影像辅助诊断、临床辅助决策等应用，推进医疗 AI 研制。                                                 |
| 2023 年<br>7 月  | 国家互联网信息办公室、国家卫生健康委等七部门    | 《生成式人工智能服务管理暂行办法》                  | 我国首份针对生成式 AI 的监管文件，要求训练数据合法合规，鼓励在医疗等领域的创新应用，为 AI 医生的发展提供了框架。                                  |
| 2023 年<br>7 月  | 国务院办公厅、国家卫生健康委等六部门        | 《深化医药卫生体制改革 2023 年下半年重点工作任务》       | 明确将医学人工智能从促进升级为加快推进，推进“5G+医疗健康”、医学人工智能试点。                                                     |
| 2024 年<br>11 月 | 国家卫生健康委等多部门               | 《卫生健康行业人工智能应用场景参考指引》               | 明确 84 个卫生健康 AI 典型应用场景，首次系统界定 AI 医疗的应用范围，强调临床辅助定位，严禁独立开展诊疗、开具处方等执业医师工作。                        |
| 2025 年<br>11 月 | 国家卫生健康委等五部门               | 《关于促进和规范“人工智能+医疗卫生”应用发展的实施意见》      | 提出 2027 年实现 AI 医疗在二级以上医院普遍应用、2030 年基层医疗机构全覆盖的目标；规范 AI 医疗数据安全、算法备案、临床验证，将 AI 医疗产品纳入医疗器械分类监管体系。 |
| 2026 年<br>1 月  | 工业和信息化部、中央网信办、国家发展改革委等八部门 | 《“人工智能+制造”专项行动实施意见》                | 明确提出加快发展手术机器人、智能诊断系统等智能医疗装备，推动产品创新与临床应用；支持研发医疗行业智能体，以远程医疗为重点场景，推进 AR/VR 等新型终端的产业化与商业化应用。      |



## 2. 分级分类监管与伦理规范同步落地

一方面，建立“技术监测、风险预警、应急响应”的全流程监管体系，要求 AI 医疗产品完成算法备案、数据合规审核，全程留痕可追溯，明确医疗机构是 AI 医疗应用的责任主体，医师对 AI 辅助诊断结果承担最终医疗责任；另一方面，多地出台地方细化监管政策，2026 年天津、江西等省市明确严禁 AI 自动生成处方、自动审核处方，要求在线处方必须经执业医师电子签名、药师审核后方可生效，彻底堵住 AI 医生越界诊疗的漏洞。

整体来看，我国 AI 医疗监管政策已从早期的鼓励探索转向“规范优先、合规落地”，核心逻辑是在保障医疗安全、维护公众健康权益的前提下，推动 AI 技术赋能医疗行业。这一政策导向直接决定了“AI 医生”的市场定位与应用边界，也成为影响公众对其可靠性认知、接受意愿的重要政策背景，公众对 AI 医生的信任度，很大程度上也依赖于政策监管的严格程度与合规保障力度。

### （三）AI 医疗市场化分析

在技术迭代与政策规范的双重驱动下，我国 AI 医疗市场化进程持续提速，市场参与主体呈现多元化布局态势，但同时也面临公众接受度滞后、基层落地成本偏高等现实困境。AI 医生作为核心应用产品，市场化推广仍处于“试点先行、逐步渗透”的阶段，尚未实现全民普及。

#### 1. 市场参与主体与产品布局

当前 AI 医疗市场形成了三大主体同台竞争的格局。一是互联网科技巨头，依托算法与算力优势，推出百度灵医智惠、腾讯觅影、阿里健康 AI 医生等通用型辅助诊疗产品，通过线上问诊、健康管理等服务达到 C 端用户需求；二是传统医疗设备与医药企业，联影医疗、迈瑞医疗等企业将 AI 模块与医疗设备结合，以“设备+AI”形式提升诊疗的效率；三是专业医疗 AI 初创企业，推出针对慢病管理、儿科、妇科等垂直领域的 AI 医生产品，满足特定医疗场景的精细化需求。同时，医保政策逐步向 AI 医疗倾斜，部分地区将 AI 辅助诊断服务纳入医疗服务价格项目，推动 AI 医生从单纯的技术投入转向可商业化运营的医疗服务。

值得关注的是，蚂蚁集团旗下的 AI 健康助手“蚂蚁阿福”<sup>[7]</sup>正成为市场新兴力量，其应用界面如图 2 所示。该应用由 AQ 应用升级更名而来，定位从“AI 工具”转向“AI 健康朋友”，集健康问答、健康陪伴、健康服务三大功能于一体。依托蚂蚁医疗大模型，它连接全国超 5000 家医院、30 万真人医生及 500 多位名医 AI 分身，提供报告解读、用药指导等服务。通过“AI 诊室”主动追问模式、智能设备数据同步等功能，强化用户健康陪伴的体验。2026 年春节期间，

蚂蚁阿福通过集福活动、长辈模式等举措，其总用户数突破 1 亿，日均健康咨询量超 1000 万次，55% 的用户来自三线及以下城市，展现出强大的市场渗透力。




图 2 蚂蚁阿福展示图

## 2. 市场化推广的核心困境

**成本与盈利矛盾突出。**AI 医生产品研发、部署与维护成本较高，多数产品依赖政府补贴与试点项目推广，自主盈利模式尚未完全成熟。

**公众接受度与认知度偏低。**行业数据显示，2025 年我国公众对 AI 医生的整体接受度仅 30% 左右，一线城市接受度约 40%，三四线城市及农村地区不足 20%，多数公众对 AI 医生的技术可靠性、隐私安全性存在疑虑，尚未形成稳定的用户习惯，但蚂蚁阿福的实践表明，通过“长辈模式”等适老化设计，以及与医保支付、智能设备的深度融合，可有效提升公众尤其是基层用户的接受度。

**技术与临床需求适配不足。**部分 AI 医疗产品重技术展示、轻临床实用，无法完全贴合基层诊疗、慢病管理等实际场景需求，如对复杂病例的处理能力有限、与医生工作流程融合度不高等，导致医疗机构使用率偏低，难以提升诊疗的效率。

**医患信任壁垒难以打破。**公众更倾向于信任执业医师的人工诊断，对 AI 算法的诊断结果存在质疑，这种信任缺失成为阻碍 AI 医生市场化推广的核心障碍。

整体而言，我国 AI 医疗市场化已进入快速发展期，市场规模与落地场景持续拓展，但 AI 医生的全民普及仍需一定的时间。蚂蚁阿福等新兴产品的市场表现，为行业提供了“技术+场景+用户”深度融合的实践参考，探索出提升公众接受度的有效路径。这一现状也为本论文的核心调研内容——公众对 AI 医生的



认知与使用意愿，提供了明确的研究切入点。

#### （四）基于 PYTHON 网络数据爬取与文本挖掘分析

##### 1. PYTHON 技术介绍与调查背景分析

随着人工智能技术在医疗领域的快速渗透，各类社交平台与网络论坛成为公众表达认知与情感的重要场域。在微博等主流社交媒体平台中，围绕“AI 医生”“AI 医疗”的讨论内容难以直接捕捉公众对 AI 医生的真实认知与情感倾向。

为了更好抓取网络舆论中关于 AI 医生的相关字段，我们选择国内活跃度高、覆盖面广的社交媒体平台“微博”作为研究数据源。近年来，微博等平台的用户评论与博文数量呈指数级增长，消费者在使用 AI 相关医疗服务后，通常会在平台发表对服务效果、使用体验等主观评价。通过对 AI 医疗相关博文进行文本挖掘，了解现阶段公众对 AI 医生的关注情况与情感态度，从而帮助我们更好研究公众对 AI 医生的认知现状、使用意愿及其市场应用潜力。通过充分利用社交媒体平台信息数据，一方面可以帮助研究者更加了解公众对 AI 医生的真实认知，合理分析影响使用意愿的关键因素；另一方面也可以为 AI 医疗企业和医疗机构提供反馈，提供更加优质的智能医疗服务。

Python 爬虫是指一段可以自动抓取互联网信息的程序，可以帮助我们在短时间内精确获取到网络上关于调查研究所需信息。本章选取了有关 AI 医疗的微博博文，通过 Python 技术爬取相关字段，经过关键词数据采集、数据清洗和分析，最终得出词云图和情感分析结果，进而为调查问卷和调查方案设计奠定基础。

##### 2. 基于 PYTHON 的 AI 医生社交媒体数据的爬取与分析

###### （1）数据爬取与清洗

微博作为目前最主要的社交媒体平台，受众群体广，消费者具有较强代表性；热门话题下的博文可以一定程度上代表公众的选择标准与真实态度。因此本研究对微博平台“AI 医生”“AI 医疗”热门话题下的讨论按热度进行分类，重点关注带有 AI 医疗服务使用的评论，最终选取 405 条有效博文进行数据爬取和分析。

###### （2）结果分析

###### 1) 基于博文内容的消费心理倾向分析

通过对同类博文进行整合，从而得到与 AI 医疗相关的词频数据。由词频排序可得公众对 AI 医生不同特征的在意程度，即频率越高该特征越可被认作 AI 医生的核心认知点，如图 3 所示。



## 2) 基于情感词典的情感性倾向分析

文本情感倾向性分析是指识别和提取原素材中的主观信息,并对带有感情色彩的文本进行分析处理和归纳推理的过程,得到情感分析结果如图 4 所示。



图 3 AI 医疗博文词频分析结果图



图 4 情感词频分析结果图

利用 Python 代码,我们通过通过 BosonNLP 情感字典分析评论情感倾向得到结果如表 2、表 3 所示。

表 2 情感倾向分布表

| 情感倾向 | 最高分数 | 最低分数 | 平均分数 | 总分数 | 总数量   | 数量占比   |
|------|------|------|------|-----|-------|--------|
| 中性   | 0.5  | 0.5  | 0.5  | 227 | 227 条 | 56.05% |
| 正面   | 0.67 | 0.52 | 0.64 | 103 | 103 条 | 25.43% |
| 负面   | 0.49 | 0.33 | 0.37 | 75  | 75 条  | 18.52% |

表 3 情感分析统计结果表

| 指标 | 分析总数  | 最高分数 | 最低分  | 平均分数 |
|----|-------|------|------|------|
| 数值 | 405 条 | 0.67 | 0.33 | 0.51 |

在社交媒体平台中,消费用户对于相应服务的评价可以很大程度上反映其直观感受,结合词频分析和博文情感值分析的结果可知:

在情感倾向分布表中可看出消费者对于 AI 医生相关服务的评论以中性为主,表明公众对于 AI 医生的认知仍处于理性观望阶段,既认可其便捷性优势,也存在对可靠性与隐私安全的顾虑;正面评价的存在表明 AI 医生具备一定的市场接受基础,而负面评价则说明其依旧存在改良的空间。

情感词频分析结果图表明 AI 医疗应重点关注公众核心关切。在提供 AI 医疗服务时应多注重便捷性、操作友好性。同时强化诊断准确性与隐私保护能力,缓解公众的顾虑。在宣传中也要注重产品特性及优势的宣传,提升公众信任度。

### 三、调查方案设计与实施

基于上述背景，本研究意识到在“健康中国 2030”与人工智能技术深度融合的时代浪潮下，AI 医疗虽在技术层面高歌猛进，却因公众审慎观望而面临现实的信任阻碍。为弥合这一“技术—公众”间的认知与信任落差，本研究不再停留于对宏观发展态势的描摹，转而将目光下沉至个体的心理与行为层面，从而为破解当前公众使用 AI 医疗的困境提供扎实的微观依据。

#### （一）调查对象

本研究选取广州市 16 岁及以上居民作为调查对象，主要基于其地域典型性与人口结构代表性。广州市作为粤港澳大湾区的核心城市，医疗体系完善、数字化水平高，拥有**丰富的 AI 医疗应用场景与政策实践**，为观察前沿技术的社会认知提供了理想场域。同时，广州兼具高度城市化与城乡共融的特征，**人口结构多元**，能较好反映不同社会群体对新兴技术的态度。聚焦于 16 岁以上人群，则是由于该群体普遍具备自主认知与决策能力，是 AI 医疗服务的潜在主要使用者，也使调查更符合伦理规范与研究可行性。通过对该群体进行问卷调查，系统收集其基本信息、认知水平与使用意愿，可为深入理解公众接受度、提出针对性策略提供扎实的实证依据。

#### （二）调查问卷的设计

（1）问卷结构：说明部分、甄别部分、主体部分、结束部分。

（2）问卷题型：单选题、多选题。

（3）甄别部分：共设置两道题。第一道是年龄筛选题，如果受访者选择年龄段为 16 岁以下，那么直接结束访问。第二道是注意力测试题，题目要求计算“1+3”的结果，未选择“3”说明专注度不够，作为废卷处理。

（4）答题逻辑检查：比如年龄在 25 岁以下且职业为学生的人月收入却在 1.5 万以上的这种，明显不符合现实逻辑，直接视为无效问卷踢除。

（5）主体部分：问卷的主体部分如表 4 所示。利用回收的问卷数据，在数据分析基础上，相互交叉进行研究，由浅入深层层递进。

表 4 调查问卷主体部分

| 问卷部分         | 具体题目                                                                                                                                           | 相关依据                                            |
|--------------|------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------|
| 基本信息         | (1) 年龄<br>(2) 性别<br>(3) 职业<br>(4) 学历<br>(5) 与谁同居<br>(6) 个人月可支配收入                                                                               | 不同年龄、性别、职业、学历、收入及家庭结构的用户，对 AI 医疗的使用意愿和需求可能存在差异。 |
| 家庭健康关注度      | (7) 就医情况自查<br>(8) 对自己健康状况的担忧程度<br>(11) 对子女健康状况的担忧程度<br>(14) 对长辈健康状况的担忧程度                                                                       | 通过调查用户对自己和家庭成员的健康关注程度，为分析外部使用场景提供依据。            |
| 对 AI 平台的信任属性 | (17) 您是否信任 AI 平台承担 AI 医疗决策错误的外部责任<br>(18) 您是否信任 AI 的医疗决策能部分取代医生的诊断<br>(19) 您是否信任 AI 在缺乏专业仪器时做出的初步医疗决策<br>(20) 您是否信任 AI 平台会严格保护隐私信息             | 通过测量用户对 AI 各个方面的信任程度，以分析信任属性对其使用意愿的影响。          |
| AI 医疗的宣传属性   | (21) 社交媒体广告打分<br>(22) 权威报道打分<br>(23) 政府推荐打分<br>(24) 亲友推荐打分                                                                                     | 探究不同宣传渠道对用户使用意愿的影响程度，为后续推广策略提供建议。               |
| AI 医疗的场景属性   | (25) 当您缺少时间时对 AI 医疗的使用意愿<br>(26) 当您日常保健时对 AI 医疗的使用意愿<br>(27) 当您面对突发情况时对 AI 医疗的使用意愿<br>(28) 当您面对敏感疾病时对 AI 医疗的使用意愿<br>(29) 当您面对严重疾病时对 AI 医疗的使用意愿 | 通过设置不同的医疗场景，模拟用户在不同情境下的真实需求，以多维度测量用户的使用意愿。      |
| AI 平台的基础属性   | (30) 提供简洁界面能力的重要性<br>(31) 准确识别文字或语音能力的重要性<br>(32) 准确理解描述的疾病能力的重要性<br>(33) 对描述的疾病做出全面诊断能力的重要性<br>(34) 对医疗检测报告进行准确解读能力的重要性                       | 通过调查用户对 AI 平台基础能力重视程度，以调查影响用户满意度和使用意愿的因素。       |
| 用户的操作属性      | (35) 您能掌握至少一种电子设备的使用<br>(36) 您能准确描述身体症状<br>(37) 您能接受使用 AI 医疗<br>(38) 您能基本学会使用电子设备和 AI                                                          | 通过测量用户的技术掌握能力、表达能力、接受度和学习能力，预测用户对 AI 医疗的使用意愿。   |

### (三) 抽样方案设计

#### 1. 抽样方法的确定

本研究调查过程采用 3 种抽样方法，分别为任意抽样、多阶段不等概率抽样和非严格的  $\pi ps$  不等概率和简单随机抽样。



①**预调查阶段：任意抽样。**在预调查阶段，采用任意抽样的方法，通过问卷星发放网络问卷并进行回收，根据预调查情况对问卷进行修改和完善。

②**正式调查阶段：非严格的  $\pi ps$  不等概率+简单随机抽样。**对于正式阶段抽样框的设计，本研究选择将广州市所有市辖区作为一级单元的抽样框，利用非严格  $\pi ps$  不等概率抽样法和简单随机抽样法进行抽样。由广州市人民政府的行政区划可知，广州市辖越秀、海珠、荔湾、天河、白云、黄埔、花都、番禺、南沙、从化、增城 11 个区，共 34 个镇、143 个街道。考虑时间成本以及问卷发放的难易程度，最终决定选择 5 个市辖区入样。根据全国第七次人口普查的结果，可获得广州市各辖区的常住人口数，具体如表 5 所示。

表 5 第七次人口普查——广州市辖区人口数据

| 广州市辖区       | 常住人口数<br>(人) | 人口数所占<br>比例 | 广州市辖区 | 常住人口数<br>(人) | 人口数所占<br>比例 |
|-------------|--------------|-------------|-------|--------------|-------------|
| 荔湾区         | 1238305      | 6.63%       | 番禺区   | 2658397      | 14.23%      |
| 越秀区         | 1038643      | 5.56%       | 花都区   | 1642360      | 8.79%       |
| 海珠区         | 1819037      | 9.74%       | 南沙区   | 846584       | 4.53%       |
| 天河区         | 2241826      | 12.00%      | 从化区   | 717684       | 3.84%       |
| 白云区         | 3742991      | 20.04%      | 增城区   | 1466331      | 7.85%       |
| 黄埔区         | 1264447      | 6.77%       |       |              |             |
| 总计 18676605 |              |             |       |              |             |

第一阶段抽样：将广州市各行政区作为初级抽样单元，采用 Python 代码法产生随机数，最终抽中海珠区、天河区、白云区、番禺区以及荔湾区。对广州 11 个市辖区的常住人口数进行赋值，结果如表 6 所示。

表 6 第一阶段抽样表

| 广州市辖区 | 常住人口数(人) | 编号                  | 随机数产生    | 是否抽中 |
|-------|----------|---------------------|----------|------|
| 荔湾区   | 1238305  | [1-1238305]         | 732938   | 是    |
| 越秀区   | 1038643  | [1238306-2276948]   |          |      |
| 海珠区   | 1819037  | [2276949-4095985]   | 2492074  | 是    |
| 天河区   | 2241826  | [4095986-6337811]   | 4783901  | 是    |
| 白云区   | 3742991  | [6337812-10080802]  | 9301832  | 是    |
| 黄埔区   | 1264447  | [10080803-11345249] |          |      |
| 番禺区   | 2658397  | [11345250-14003646] | 11814579 | 是    |
| 花都区   | 1642360  | [14003647-15646006] |          |      |
| 南沙区   | 846584   | [15646007-16492590] |          |      |
| 从化区   | 717684   | [16492591-17210274] |          |      |
| 增城区   | 1466331  | [17210275-18676605] |          |      |

通过计算机生成[1-18676605]范围中的随机数，若生成的随机数落在市辖区所在的编号区间内，则选择该辖区。例如，若生成的随机数为 732938，则选择

在[1-1238305]范围内，则选择荔湾区入样。若生成的随机数所在的市辖区已被选择，则该随机数作废，再次生成随机数，直至选择完所需的 5 个市辖区。最后选择荔湾区、海珠区、天河区、白云区以及番禺区入样。表中展示的随机数仅为对应行政区最终判定入样时所生成的有效随机数。

第二阶段抽样：采用与第一阶段相同的方法，对各区街道按照常住人口数进行重新编号，利用 Python 代码法产生随机数抽取街道，每个市辖区抽取 3 个街道。由于街道众多，此处仅展示结果，第二阶段抽样结果如表 7 所示。

表 7 第二阶段抽样结果

| 广州市辖区 | 街道数（个） | 抽取个数 | 抽中街道名称 |        |       |
|-------|--------|------|--------|--------|-------|
| 荔湾区   | 22     | 3    | ①西村街道  | ②桥中街道  | ③华林街道 |
| 海珠区   | 18     | 3    | ①滨江街道  | ②南华西街道 | ③瑞宝街道 |
| 天河区   | 11     | 3    | ①员村街道  | ②林和街道  | ③长兴街道 |
| 白云区   | 24     | 3    | ①景泰街道  | ②三元里街道 | ③同德街道 |
| 番禺区   | 16     | 3    | ①钟村街道  | ②沙湾街道  | ③桥南街道 |
| 合计    | 91     |      | 15     |        |       |

第三阶段抽样：采用简单随机抽样，将第二阶段抽取的 5 个市辖区中每个街道的每个社区进行编码，利用 Python 代码法抽取社区，每个街道抽取 3 个社区。最终在抽中的社区中发放问卷，并进行问卷回收，统计相关数据结果。

2.抽样框编制

根据抽样方案，编制抽样框如表 8 所示。

表 8 样本框设定表

| 第一阶段抽样框    | 第二阶段抽样框 | 第三阶段抽样框   | 第四阶段抽样框                             |
|------------|---------|-----------|-------------------------------------|
| 广州 11 个市辖区 | 海珠区所有街道 | 滨江街道所有社区  | 远安社区所有居民<br>中海社区所有居民<br>益丰社区所有居民    |
|            |         | 南华西街道所有社区 | 敬和里社区所有居民<br>聚龙社区所有居民<br>后乐园社区所有居民  |
|            |         | 瑞宝街道所有社区  | 南约社区所有居民<br>瑞宝花园社区所有居民<br>金碧西社区所有居民 |
|            | 天河区所有街道 | 员村街道所有社区  | 侨颖社区所有居民<br>南富社区所有居民<br>四横路社区所有居民   |
|            |         | 林和街道所有社区  | 侨庭社区所有居民                            |
|            |         |           |                                     |
|            |         |           |                                     |
|            |         |           |                                     |
|            |         |           |                                     |

|         |           |            |
|---------|-----------|------------|
|         |           | 恒怡社区所有居民   |
|         |           | 紫荆社区所有居民   |
|         | 长兴街道所有社区  | 岑村西社区所有居民  |
|         |           | 天鹅社区所有居民   |
|         |           | 兴韵社区所有居民   |
| 白云区所有街道 | 景泰街道所有社区  | 平安社区所有居民   |
|         |           | 降康社区所有居民   |
|         |           | 景泰西社区所有居民  |
|         | 三元里街道所有社区 | 机场第二社区所有居民 |
|         |           | 松柏岗社区所有居民  |
|         |           | 西约社区所有居民   |
|         | 同德街道所有社区  | 积德社区所有居民   |
|         |           | 泽德社区所有居民   |
| 番禺区所有街道 | 钟村街道所有社区  | 同雅苑社区所有居民  |
|         |           | 龙岐村所有居民    |
|         |           | 沙坑村所有居民    |
|         |           | 金沙湾社区所有居民  |
|         | 沙湾街道所有社区  | 胜石村所有居民    |
|         |           | 锦绣花园社区所有居民 |
|         |           | 钟村社区所有居民   |
|         | 桥南街道所有社区  | 福景社区所有居民   |
|         |           | 番禺社区所有居民   |
| 荔湾区所有街道 | 西村街道所有社区  | 新世纪社区所有居民  |
|         |           | 广雅社区所有居民   |
|         |           | 协和社区所有居民   |
|         |           | 西湾社区所有居民   |
|         | 桥中街道所有社区  | 东海社区所有居民   |
|         |           | 恒海社区所有居民   |
|         |           | 双桥社区所有居民   |
|         | 华林街道所有社区  | 光复社区所有居民   |
|         |           | 兴贤社区所有居民   |
|         |           | 河傍社区所有居民   |

#### (四) 样本量的确定

由第七次人口普查数据可知，广州市共有常住人口 18676605，则样本量  $N=18676605$ ，根据预调查样本的各题得分方差均值作为最终总体方差的  $S^2$ （预调查计算得到的约为 0.817）。取置信水平为 95%，查表可得分位值为 1.96，故取绝对误差限  $d=0.10$ ，代入下面的公式计算初始样本量：

$$n_0 = \frac{1}{\frac{1}{N} + \frac{d^2}{z_{\alpha/2}^2 S^2}} \approx 314 \quad (1)$$



本次抽样的方案为多阶段抽样，设计  $Deff$  效应对样本容量进行微调，由于抽样方案复杂，难以计算实际抽样方案的效用，通过查阅相关文献，取  $Deff=2$ ，则所需样本量为：

$$n_1 = n_0 \times Deff \approx 628 \quad (2)$$

根据预调查的样本有效回收率  $r = 89\%$  确定最终样本容量：

$$n_2 = \frac{n_1}{r} \approx 705 \quad (3)$$

由此，我们确定样本容量为 705，在最后对每个社区的抽样中，我们采用等额抽样，每个社区应分配的样本量为 16 人。

同时我们采用线上线下相结合的方式收集问卷。

线下调查以社区定点调查为主，由本小组 5 位调查员分时段、分批次开展现场问卷发放。针对工作日居民外出等问题，我们采取在工作日晚间、以及周末全天错峰调查的模式，延长单社区调查时长，确保覆盖不同职业、不同年龄段的群体。对填写不便的老年人，调查员也准备大字版本的调查问卷，并采用一对一读题方式协助完成。考虑到部分群体，如老年人的媒介素养较低，在填写问卷前由调查员向其对 AI 医疗相关情况以及问卷内容进行简单解释后再进行问卷的填写。

线上调查采用问卷星电子问卷，联系社区居委会以及小区物业，通过业主群、物业公告、社区公众号、等正规渠道定向推送。同时，我们还为线下受访居民提供扫码填写通道。线上线下数据实时同步，统一纳入后台数据。

## （五）数据质量控制

在调查实施过程中，受多重因素影响，误差的出现客观存在。为此我们全程贯彻严格的质量控制机制，力求将各类误差压缩至最低水平。

在调查**前期**，我们围绕研究主题组织多次专题研讨，系统厘清调查目标、核心内容与实施流程；在编制问卷编制时我们广泛查阅国内外权威文献，确保题项设置具备理论支撑、逻辑严密，提升问卷的科学性与合理性。在调查**执行阶段**，通过添加通俗化脚注、开展预测试优化表述，并结合专家访谈等多元方法交叉验证，切实降低理解偏差，提高应答真实性、信息准确性与覆盖全面性。在调查**后期**，我们对回收问卷实行三级质量审核：其一，剔除作答时长小于 1 分钟、关键题项漏答或明显乱答等无效问卷；其二，在数据录入前核对纸质问卷与电子记录，最大限度规避人工转录错误；其三，我们统一编码、双机独立录入并进行逻辑校验比对。最终对分析结果执行多轮稳健性检验，确保研究结论的真实性与可靠性。

## （六）信效度检验

### 1. 预调查的信效度检验

在正式调查之前，本小组成员在广州市内采用任意抽样的方法随机发放问卷进行预调查，以检验所设计的抽样方案及抽样框、调查问卷的科学性和可操作性。在此次预调查中共发放 100 份问卷，剔除无效问卷 11 份，其中有效问卷为 89 份，样本回收率 89%，根据收集的有效问卷进行信效度检验，发现可能存在的问题。

#### （1）信度检验

信度即可靠性，信度检验是社会科学与实证研究中用于评价问卷、量表等测量工具稳定性与内部一致性的重要统计分析环节，其目的在于检验测量结果是否受随机误差干扰，确保同一概念的多个题项之间具有较高的同质性与可靠性。在问卷与量表分析中，最常用的评价指标为 Cronbach  $\alpha$  系数，该系数取值介于 0~1 之间，数值越高表明量表内部一致性越好、测量结果越稳定可信，通常以  $\alpha \geq 0.8$  作为量表信度可接受的标准。对预调查数据进行信度检验的结果如表 9 所示。

表 9 各变量信度分析结果

| 层面   | 对应题项   | Cronbach $\alpha$ 系数 | 总体的 Cronbach $\alpha$ 系数 |
|------|--------|----------------------|--------------------------|
| 信任属性 | Q17-20 | 0.844                | 0.916                    |
| 宣传属性 | Q21-24 | 0.803                |                          |
| 场景属性 | Q25-29 | 0.827                |                          |
| 基础属性 | Q30-34 | 0.932                |                          |
| 用户属性 | Q35-38 | 0.861                |                          |

若 Cronbach' Alpha 系数大于 0.9，则说明信度非常好；若系数介于 0.8 到 0.9 之间，则说明信度好；若系数介于 0.7 到 0.8 之间，则说明信度较好，但仍有部分题目需要改正；若系数低与 0.6，说明信度不佳。如上表所示，每项变量 Cronbach' Alpha 系数均在 0.8 以上，说明问卷的指标具有可靠性。

#### （2）效度检验

效度分析是一种用于检验问卷有效性和准确程度的方法，其主要目的在于验证测量工具是否能够准确地反映所要测量对象的特质程度。效度越高，表明量表题项能够有效反映其所对应的潜在变量，研究结果越具有真实性与解释力。一般而言，效度分析会针对问卷的结构效度进行测量对此通常采用因子分析方法来进行效度检验。而在这一过程中，一般会运用 KMO 和 Bartlett 球形度检验作为检验标准。KMO 和 Bartlett 球形度检验的检验结果如表 10 所示：

表 10 KMO 和巴特利特检验结果

| KMO 值          | 0.821         |          |
|----------------|---------------|----------|
| Bartlett 球形度检验 | 近似卡方 $\chi^2$ | 1404.370 |
|                | df            | 231      |
|                | P 值           | 0.000    |

其中，KMO 检验值为 0.821，Bartlett 球形度检验的 P 值小于 0.001，说明预调查问卷具有良好的效度。

## 2. 正式调查的信效度检验

通过线上线下结合的方式进行抽样，最终收集到 825 份问卷，剔除 98 份无效问卷，有效问卷 727 份，问卷有效率 88.12%。

### (1) 信度检验

为保证问卷的有效性，我们对预调查所得的问卷数据进行信度检验后，并根据所得数据对问卷进行修改，在形成正式问卷并发放后，对正式问卷所得数据进行信度分析，结果如表 11 所示。

表 11 正式调查信度检验结果表

| 层面   | 对应题项   | Cronbach $\alpha$ 系数 | 总体的 Cronbach $\alpha$ 系数 |
|------|--------|----------------------|--------------------------|
| 信任属性 | Q17-20 | 0.952                | 0.9497                   |
| 宣传属性 | Q21-24 | 0.880                |                          |
| 场景属性 | Q25-29 | 0.894                |                          |
| 基础属性 | Q30-34 | 0.901                |                          |
| 用户属性 | Q35-38 | 0.898                |                          |

### (2) 效度检验

对正式问卷的结果进行检验，KMO 检验和 Bartlett 球形检验结果如表 12 所示，KMO 值为 0.9462，大于 0.8，Bartlett 球形检验值的 P-值为 0.000，小于 0.05，这说明预调查问卷具有良好的效度。

表 12 正式调查 KMO 和巴特利特检验结果

| KMO 值          | 0.946         |           |
|----------------|---------------|-----------|
| Bartlett 球形度检验 | 近似卡方 $\chi^2$ | 11174.014 |
|                | df            | 231       |
|                | P 值           | 0.000     |

## (七) 调查组织工作和实施过程

### 1. 调查组织工作

为了系统性地开展调查研究活动，我们先学习了问卷设计的流程与分析方法，



然后根据各个组员的优势进行合理分工,图 5 便为本次小组调研的具体分工。详细线下调查过程见附录三。




图 5 团队分工图

## 2. 调查进度实施

本次调研实施工作进度安排如图 6 所示。





图 6 调查进度图

## 四、描述性统计分析

### （一）受访者基本信息

#### 1. 性别分布——男女比例相当

正式调查共得到问卷 825 份，有效问卷 732 份，有效率 88.74%。如图 7 所示，在回收的有效问卷中，男性占 43.67%，女性占 57.24%，男女比例相对均衡。



数据来源：线上+线下

图 7 受访者性别比例

#### 2. 年龄分布——19-25 岁群体占比居多

在问卷受访者中，如图 8 所示，19-25 岁群体所占比例最高，占比 29%；31-40 岁群体占比最低，占比 10.2%。与广州市居民总体年龄分布相比，年龄段位于 19-25 岁的群体比例较高。究其原因，在对 AI 医疗使用现状调查时，19-25 岁这个年龄段群体对于填写问卷更为积极。




图 8 受访者年龄占比

#### 3. 受访者的收入水平——中等收入水平的个人比较多

如图 9 所示，个人月可支配收入在 5000-10000 元的受访者最多，总体占比为 18.58%。2000-5000 和 10000-15000 的月可支配收入人群分别为其贡献了 18.31%和 18.44%的占比。同时，86.34%的受访者有 2000 元以上的月可支配收入。

总体而言，公众基本可以承担起使用 AI 看病所需的支出。




图9 受访者（人均）月可支配收入占比

### 3. 受访者具备的内在技能水平——中等偏上的占多数

根据问卷结果得出受访者在学习能力、表达能力、接受能力、对电子设备的操作能力四个维度的自我评估情况分析如表 13 所示，四个维度的平均得分为 3.81 分（5 分制），表明受访者群体整体上对使用 AI 医疗工具所需的核心能力持有较为积极的自我评价。

表 13 AI 大模型用户属性对使用意愿影响的平均值（含标准误差）统计

| 信任属性维度     | 平均值  | 标准误差  | 总体平均得分 |
|------------|------|-------|--------|
| 掌握电子设备能力   | 3.95 | 0.038 | 3.81   |
| 描述病症能力     | 3.77 | 0.035 |        |
| 接受 AI 能力   | 3.67 | 0.036 |        |
| 学会使用 AI 能力 | 3.83 | 0.036 |        |

## （二）受访者对 AI 医疗的认知与使用现状

### 1. 认知情况

由图 10、11 可知，受访者对 AI 医疗决策的认知水平呈现出“广度尚可，深度不足”的显著特点。数据显示，有 79.1% 的受访者表示“知道”AI 可以用于辅助医疗决策。然而，在 5 分制（1=非常不了解，5=非常了解）的量表下，其了解程度在 3 分以上的只有 27.57%，表明大部分用户的认知停留在“听说过但了解不深”的阶段。这种认知鸿沟意味着，AI 看病市场普及工作已成功吸引了广泛关注，但向深度理解和信任的转化仍是关键挑战。







图 10 受访者对 AI 医疗的认知情况图 图 11 受访者对 AI 医疗的了解程度图

## 2. 使用现状

与认知情况相比，AI 医疗决策的实际使用率较低，处于萌芽时期，市场处于“认知先行，使用滞后”的早期导入阶段。如图 12 所示，在所有受访者中，仅有 42.2% 的用户表示有过使用 AI 进行医疗决策（如在线自诊、辅助解读报告等）的实际经验。这与较高的知晓度（79.1%）形成了鲜明对比，表明从“知道”到“使用”之间存在巨大的行为转化断层。




图 12 受访者是否使用过 AI 大模型进行医疗决策

## （三）受访者对 AI 医疗的内在态度

### 1. 信任情况

由表 14 可知在 5 分制（1=完全不信任，5=完全信任）的量表下，受访者对 AI 医疗的总体信任度平均得分为 3.04。然而，具体维度的信任度存在显著差异：①用户对“AI 平台承担诊断错误责任”（均值 3.12）的信任度相对较高，这表明用户倾向于认可 AI 平台承担责任的能力。②用户对“AI 平台保护用户隐私”（均值 3.09）和“AI 在无仪器决策的情况下做出的结果”（均值 3.02）的信任度处于中等水平，说明人们对 AI 辅助性、工具性价值，及其隐私保护能力有一

定基础期待。③用户对“AI 诊断完全替代医生”（均值 2.93）的信任度明显偏低，这清晰地反映出 AI 医疗的专业性还不足以让公众信服。

表 14 AI 大模型信任属性对使用意愿影响的平均值（含标准误差）统计

| 信任属性维度     | 平均值  | 标准误差  | 总体平均得分 |
|------------|------|-------|--------|
| 信任平台承担错误能力 | 3.12 | 0.037 | 3.04   |
| 信任取代医生诊断   | 2.93 | 0.039 |        |
| 信任无仪器决策结果  | 3.02 | 0.040 |        |
| 信任平台保护隐私   | 3.09 | 0.040 |        |

## 2. 宣传影响效力

由表 15 可以看出，用户对四类宣传渠道的整体信任与接受程度由高到低依次为：政府推荐、权威媒体报道、亲友推荐、社交媒体广告。“政府推荐”是影响用户决策的最强因素，其影响力平均得分为 3.71，显著高于其他渠道，这说明人们对政府政策的信任程度非常高。相反，“社交媒体广告”的影响力最低，平均得分只有 3.27，这说明用户对商业化、主动推送的广告信息普遍持谨慎甚至抵触态度。总体平均得分为 3.50，这说明宣传属性能在一定程度上提升用户对 AI 大模型的使用意愿。

表 15 AI 大模型宣传属性对使用意愿影响的平均值（含标准误差）统计

| 宣传属性维度 | 平均值  | 标准误差  | 总体平均得分 |
|--------|------|-------|--------|
| 社交媒体广告 | 3.27 | 0.038 | 3.50   |
| 权威媒体报道 | 3.63 | 0.035 |        |
| 政府推荐   | 3.71 | 0.037 |        |
| 亲友推荐   | 3.38 | 0.035 |        |

## 3. 使用场景偏好

在 5 分制（1=非常不愿意，5=非常愿意）量表下，用户对 AI 医疗的应用场景偏好呈现明确的梯度分化，价值主张高度依赖于情境的轻重缓急。由表 16 可知：①受访者在“时间紧张，没空去医院”和“日常健康咨询与保健”两种场景下的使用意愿最为强烈，平均使用意愿得分分别为 3.53 和 3.62。这凸显了 AI 医疗的核心吸引力在于其便捷性、即时性和预防性健康管理价值，是解决“看病难、看病烦”和满足日常健康需求的潜在优选方案。②在涉及“严重或疑难疾病”和“涉及个人隐私的敏感疾病”时，用户的使用意愿降至冰点，平均使用意愿得分分别为 3.21 和 3.38。这表明，在面对高不确定性、高风险以及高私密性的健康问题，用户对 AI 的决策能力和安全性存在严重不信任，更倾向于依赖传统医疗体系。③在“突发不适，需要初步判断”时，用户意愿平均使用意愿得分为 3.41，体现出一种“可尝试但需谨慎”的过渡心态。

表 16 AI 大模型场景属性对使用意愿影响的平均值（含标准误差）统计

| 场景属性维度 | 平均值  | 标准误差  | 总体平均得分 |
|--------|------|-------|--------|
| 缺少时间   | 3.53 | 0.036 | 3.43   |
| 日常保健   | 3.62 | 0.035 |        |
| 突发情况   | 3.41 | 0.040 |        |
| 敏感疾病   | 3.38 | 0.040 |        |
| 严重疾病   | 3.21 | 0.043 |        |

#### 4. 功能需求

由表 17 可以看出，在 5 分制（1=完全不重要，5=非常重要）的量表下，用户对 AI 医疗工具的功能需求呈现“基础体验优先，核心能力期待”的鲜明特点。①用户对“操作界面简洁易懂”（均值 3.79）和“能准确识别我输入的文字或语音”（均值 3.95）表现出较高期待。这表明用户对 AI 医疗最核心的需求是易用性与交互准确性，任何功能强大的 AI 医疗产品，其成功的第一道门槛是极致的用户体验和零误差的交互。②“准确诊断疾病”（均值 3.96）、“能准确分析病情并给出诊断建议”（均值 3.98）和“能解读化验单、影像报告等医疗文件”（均值 4.00）是用户需求最强烈的两个功能点。这反映了用户希望 AI 不仅是一个信息查询工具，更能提供有深度的、个性化的诊疗辅助，尤其是解决报告看不懂、病情理解不透彻的痛点。

表 17 AI 大模型基础属性对使用意愿影响的平均值（含标准误差）统计

| 基础属性维度   | 平均值  | 标准误差  | 总体平均得分 |
|----------|------|-------|--------|
| 简洁界面     | 3.79 | 0.037 | 3.94   |
| 准确识别语言   | 3.95 | 0.038 |        |
| 准确理解疾病   | 4.00 | 0.040 |        |
| 准确诊断疾病   | 3.96 | 0.038 |        |
| 准确解读检测报告 | 3.98 | 0.038 |        |

#### （四）受访者对 AI 医疗当前和未来的使用意愿对比

由图 13 左半部分可以看出，在 5 分制（1=非常不愿意，5=非常愿意）的量表下，受访者表示基于现在的 AI 医疗技术发展情况，他们对 AI 医疗的使用意愿的平均得分为 3.29。但是如果 AI 医疗技术能够实现改良升级，用户表示在未来对 AI 医疗的使用意愿平均为 3.86。这说明 AI 医疗技术在未来还有很大的市场和发展机会。从图 13 右半部分可以更直观地看出当前愿意使用 AI 医疗的人群中，对现有模式的评分不高于 3 分的占比约 59.3%；而有 70.4% 的受访者对未来期望的模式更偏向 4-5 分的高分段。这反映出用户对 AI 医疗未来的改进方向有较高期待，且当前使用意愿的评分分布与未来期望存在明显差异。






图 13 受访者对 AI 医疗当前和未来的使用意愿得分对比图

图 14 展示了当前对 AI 医疗使用意愿较低评分与未来对其模式期望高评分交叉的人群分布，总人数为 189 人。其中，当前意愿评分最低（1 分）但未来期望高（4-5 分）的有 4 人，当前意愿偏低（2 分）而未来期望高的有 33 人，而当前意愿中等（3 分）但未来期望高的人数高达 152 人，占比超过 80%。这一分布表明，绝大多数“当前意愿中等”的群体是提升未来使用率的关键潜在转化对象，他们对 AI 医疗的发展抱有较高期待。少数“当前意愿偏低”的群体也显示出可挖掘的转化潜力。而“当前意愿极低”的群体向高期望转化的比例极低，应作为次要关注对象。该图直观揭示了优化技术与服务应优先锁定“当前意愿中等”群体，通过针对性改进来提高其使用意愿，实现用户规模与满意度的同步提升。




图 14 未来使用意愿提升的用户数量统计图

## 五、基于 Logistic 回归模型的 AI 医疗用户特征分析

我们通过描述性统计初步揭示了公众对 AI 医疗决策意愿的宏观态势，为进一步识别驱动公众参与行为的核心人口学特征<sup>[22]</sup>，本章引入二元 Logistic 回归模型，通过定量评估年龄、学历、收入等用户基本特征的显著性贡献，为后续深入探究其内在影响机理奠定基础。

### （一）二元 Logistic 回归模型的构建

#### 1. 原理介绍

二元选择模型是基于个体在两类互斥备选方案中进行唯一抉择的行为特征所构建的计量模型。在本研究中，研究对象是否使用过 AI 进行医疗决策的回答仅存在两种互斥结果，对应因变量为二分类变量，因此本小组选择构建二元选择模型展开分析。二元选择模型主要包含线性概率模型、Probit 模型与 Logistic 模型三类，其中 Logistic 模型在应用场景的适配性与经济意义的解释性上均具备显著优势，故小组最终确定采用 Logit 模型作为本研究的核心计量模型。

Logistic 回归属于广义线性模型（Generalized Linear Model, GLM）范畴，是针对二分类因变量的经典参数回归方法，区别于传统线性回归直接拟合连续型因变量，它通过 Logit 连接函数，将无界的线性预测值精准映射至  $[0, 1]$  标准概率区间，实现二分类事件发生概率的量化建模与推断。

#### 2. 模型构建

基于研究内容，我们以用户是否使用过 AI 进行医疗决策作为因变量，以用户的年龄、性别、职业等基本信息作为自变量进行回归，建立 Logistic 模型如下：

$$\ln\left(\frac{P_i}{1-P_i}\right) = \beta_0 + \beta_1 \text{Age1} + \beta_2 \text{Age2} + \beta_3 \text{Age3} + \beta_4 \text{Age4} \\ + \beta_5 \text{Age5} + \beta_6 \text{Age6} + \beta_7 \text{Sex} + \beta_8 \text{Career1} \\ + \beta_9 \text{Career2} + \beta_{10} \text{Career3} + \beta_{11} \text{Career4} + \beta_{12} \text{Edu1} \\ + \beta_{13} \text{Edu2} + \beta_{14} \text{Edu3} + \beta_{15} \text{Con1} + \beta_{16} \text{Con} + \beta_{17} \text{Con3} \\ + \beta_{18} \text{Con4} + \beta_{19} \text{Con5} + \beta_{20} \text{Fam1} + \beta_{21} \text{Fam2} \\ + \beta_{22} \text{Fam3} \quad (4)$$

根据用户的特征类别，将各分类变量进行虚拟变量处理，并以便于模型结果分析为原则设定基准类，对所需相关指标的量化处理结果如表 18 所示。

表 18 用户特征变量定义表

| 变量名    | 变量符号    | 变量定义                                              |
|--------|---------|---------------------------------------------------|
| 年龄     | Age1    | Age1=(1=16-18 岁, 0=19-25 岁)                       |
|        | Age2    | Age2=(1=26-30 岁, 0=19-25 岁)                       |
|        | Age3    | Age3=(1=31-40 岁, 0=19-25 岁)                       |
|        | Age4    | Age4=(1=41-50 岁, 0=19-25 岁)                       |
|        | Age5    | Age5=(1=51-60 岁, 0=19-25 岁)                       |
|        | Age6    | Age6=(1=61-70 岁, 0=19-25 岁)<br>以 19-25 岁为基础类型     |
| 性别     | Sex     | Sex=(1=女, 0=男)                                    |
| 职业     | Career1 | Career1=(1=退休人员, 0=学生)                            |
|        | Career2 | Career2=(1=普通职员, 0=学生)                            |
|        | Career3 | Career3=(1=自由职业者, 0=学生)                           |
|        | Career4 | Career4=(1=事业单位职员, 0=学生)<br>以学生为基础类型              |
| 学历     | Edu1    | Edu1=(1=专科, 0=高中及以下)                              |
|        | Edu2    | Edu2=(1=本科, 0=高中及以下)                              |
|        | Edu3    | Edu3=(1=硕士及以上, 0=高中及以下)以高中及以<br>下为基础类型            |
| 月可支配收入 | Con1    | Con1=(1=2000-5000 元, 0=2000 元以下)                  |
|        | Con2    | Con2=(1=5000-10000 元, 0=2000 元以下)                 |
|        | Con3    | Con3=(1=10000-15000 元, 0=2000 元以下)                |
|        | Con4    | Con4=(1=15000-20000 元, 0=2000 元以下)                |
|        | Con5    | Con5=(1=20000 元以上, 0=2000 元以下)<br>以 2000 元以下为基础类型 |
| 同居亲属   | Fam1    | Fam1=(1=父母, 0=子女)                                 |
|        | Fam2    | Fam2=(1=爷爷/奶奶/外公/外婆, 0=子女)                        |
|        | Fam3    | Fam3=(1=无, 0=子女)<br>以子女为基础类型                      |

### 3. 模型回归结果

在 0.05 的显著性水平下, 本项目小组利用统计分析软件进行 Logistic 回归分析得到回归结果如表 19 所示。

从回归结果来看, 各年龄亚组变量的 P 值均远大于 0.05, 均未达到统计学显著水平, 标准化系数绝对值介于 0.011~0.109 之间, 对因变量的影响强度极弱, 表明年龄维度对因变量发生概率无实质性预测作用。



表 19 二元 Logistic 模型回归结果

| 变量      | 回归系数   | 标准误差  | P 值      | OR 值   |
|---------|--------|-------|----------|--------|
| Age1    | -0.190 | 0.377 | 0.615    | 0.827  |
| Age2    | -0.138 | 0.378 | 0.715    | 0.871  |
| Age3    | -0.361 | 0.426 | 0.397    | 0.697  |
| Age4    | 0.035  | 0.390 | 0.929    | 1.035  |
| Age5    | -0.234 | 0.395 | 0.554    | 0.792  |
| Age6    | -0.193 | 0.388 | 0.620    | 0.825  |
| Sex     | 2.492  | 0.261 | 0.000*** | 12.084 |
| Career1 | -0.852 | 0.371 | 0.022*   | 0.427  |
| Career2 | -0.705 | 0.353 | 0.046*   | 0.494  |
| Career3 | -0.666 | 0.333 | 0.046*   | 0.514  |
| Career4 | -0.826 | 0.349 | 0.018*   | 0.438  |
| Edu1    | 0.012  | 0.352 | 0.973    | 1.012  |
| Edu2    | 0.399  | 0.300 | 0.183    | 1.490  |
| Edu3    | 3.295  | 0.365 | 0.000*** | 26.977 |
| Con1    | 0.437  | 0.394 | 0.268    | 1.548  |
| Con2    | 0.693  | 0.384 | 0.071    | 1.999  |
| Con3    | 2.214  | 0.398 | 0.000*** | 9.149  |
| Con4    | 0.337  | 0.413 | 0.414    | 1.401  |
| Con5    | 0.373  | 0.411 | 0.364    | 1.452  |
| Fam1    | 2.679  | 0.291 | 0.000*** | 14.573 |
| Fam2    | -0.279 | 0.278 | 0.315    | 0.756  |
| Fam3    | 0.577  | 1.159 | 0.618    | 1.782  |

注：\*\*\*，\*\*，\*分别表示在 0.1%，1%，5%的水平下显著

此外，我们采用受试者工作特征(receiver operating characteristic, ROC)曲线来评价单一变量以及整个模型对因变量的区分与预测能力，结果如图 15 所示。




图 15 ROC 曲线图

从图中可以看出，年龄单一维度的 ROC 曲线下面积（AUC=0.501951）无限接近于 0.5 的参考线，说明年龄变量对因变量的判别区分能力处于随机水平，无法有效区分因变量的不同取值类别。

因此，年龄变量并不具备统计学显著意义，预测能力弱。本研究在后续 Logistic 回归分析中剔除年龄变量，采用剔除后的核心变量集重新构建回归模型，以保证模型的拟合质量与实际应用价值。剔除年龄变量后构建模型如下：

$$\ln\left(\frac{P_i}{1-P_i}\right) = \beta_0 + \beta_1 \text{Sex2} + \beta_2 \text{Career2} + \beta_3 \text{Career3} + \beta_4 \text{Career4} \\ + \beta_5 \text{Career5} + \beta_6 \text{Edu2} + \beta_7 \text{Edu3} + \beta_8 \text{Edu4} + \beta_9 \text{Con2} \\ + \beta_{10} \text{Con3} + \beta_{11} \text{Con4} + \beta_{12} \text{Con5} + \beta_{13} \text{Con} + \beta_{14} \text{Fam2} \\ + \beta_{15} \text{Fam3} + \beta_{16} \text{Fam4} \quad (5)$$

对数据进行 Logistic 回归的结果如表 20 所示：

表 20 剔除年龄变量后二元 Logistic 模型回归结果

| 变量                      | 回归系数   | 标准误差  | P 值      | OR     |
|-------------------------|--------|-------|----------|--------|
| 性别(女)                   | 2.517  | 0.259 | 0.000*** | 12.385 |
| 职业（退休人员）                | -0.913 | 0.355 | 0.0101*  | 0.401  |
| 职业（普通职员）                | -0.768 | 0.337 | 0.023*   | 0.464  |
| 职业（自由职业者）               | -0.703 | 0.317 | 0.027*   | 0.495  |
| 职业（事业单位职员）              | -0.869 | 0.338 | 0.010*   | 0.420  |
| 学历（专科）                  | 0.014  | 0.350 | 0.969    | 1.014  |
| 学历（本科）                  | 0.399  | 0.299 | 0.182    | 1.490  |
| 学历：硕士及以上                | 3.279  | 0.363 | 0.000*** | 26.556 |
| 月可支配收入<br>(2000-5000)   | 0.466  | 0.387 | 0.229    | 1.593  |
| 月可支配收入<br>5000-10000    | 0.718  | 0.379 | 0.058    | 2.050  |
| 月可支配收入<br>(10000-15000) | 2.218  | 0.397 | 0.000*** | 9.193  |
| 月可支配收入<br>(15000-20000) | 0.341  | 0.410 | 0.406    | 1.406  |
| 月可支配收入(>20000)          | 0.361  | 0.408 | 0.376    | 1.435  |
| 同居亲属（父母）                | 2.630  | 0.286 | 0.000*** | 13.874 |
| 同居亲属(爷爷/奶奶/外公/外婆)       | -0.329 | 0.272 | 0.227    | 0.720  |
| 同居亲属（无）                 | 0.638  | 1.161 | 0.583    | 1.893  |

注：\*\*\*，\*\*，\*分别表示在 0.1%，1%，5%的水平下显著

采用 ROC 曲线来评价各单一变量及整个模型对因变量的区分与预测能力，结果如图 16、表 21 所示。




图 16 剔除年龄变量后 ROC 曲线图

表 21 单一变量 AUC 结果

| 变量      | AUC 值 |
|---------|-------|
| Sex2    | 0.668 |
| Career4 | 0.479 |
| Edu4    | 0.638 |
| Con4    | 0.584 |
| Fam2    | 0.677 |
| 总体模型    | 0.906 |

单一维度变量的 ROC 曲线分析结果显示，各核心自变量的曲线下面积（AUC）均介于 0.479 至 0.677 之间，未达到 0.75 的强判别水平，表明单个特征对因变量的独立区分能力有限，难以实现有效预测。其中，家庭背景（Fam2，AUC=0.677）与性别（Sex2，AUC=0.668）表现出相对更优的判别效能，而职业（Career4，AUC=0.479）的独立预测价值最弱。

尽管单一特征的判别能力有限，本研究构建的总体 Logistic 回归模型仍展现出极强的综合预测效能。总体模型 ROC 曲线下面积（AUC=0.906）远高于各单一变量，曲线形态显著靠近左上角，明显优于随机判别基准。这一结果充分说明，单一特征虽缺乏独立预测价值，但多特征通过 Logistic 模型的整合形成了显著的协同效应，实现了对因变量类别的高效区分，验证了多变量构建模型在本研究中的必要性。同时，在剔除无显著预测价值的年龄变量后，模型 AUC 仍保持在 0.9 以上，既提升了模型简洁性，又未损失核心判别效能，进一步印证了变量筛选策略的科学性。

#### 4. 模型检验

对模型进行似然比卡方检验可知，卡方值为 411.456，拟合 p 值为 0.000，



说明构建的 Logistic 模型具有较好显著性，能够用于分析用户的各核心特征对使用 AI 医疗决策行为的影响，模型整体解释力较强，具备可靠的预测与分析价值。检验结果如表 22 所示。

表 22 似然比卡方检验结果

| 模型   | 卡方值     | 自由度 | P 值      |
|------|---------|-----|----------|
| 总体模型 | 411.456 | 22  | 0.000*** |

## （二）模型结果分析

### 1. 性别

在性别维度的检验中，相较于基准类男性群体，女性的回归系数为 2.517，在 0.1% 的水平下显著，且 OR 值显著大于 1，说明女性相对于男性更倾向于使用 AI 进行医疗决策。

### 2. 职业

在职业维度的检验中，相较于基准类学生群体，退休人员、普通职员、自由职业者、事业单位职员的回归系数均为负，均在 5% 的水平下显著，且 OR 值均小于 1。这一结果说明，学生群体更倾向于使用 AI 进行医疗决策，而其他职业群体对 AI 医疗工具的使用意愿相对保守。

### 3. 学历

在学历维度的检验中，相较于基准类高中及以下学历群体，专科与本科学历的回归系数均未达到统计学显著水平，表明二者对用户使用 AI 进行医疗决策的行为无显著影响。而硕士及以上学历的 P 回归系数为 3.279，在 0.1% 的水平下显著。这一结果说明，高学历群体更倾向于使用 AI 进行医疗决策。

### 4. 个人月可支配收入

在月可支配收入维度的检验中，以月可支配收入 2000 元以下群体为基准参照组，收入为 2000-5000 元、15000-20000 元及 20000 元以上群体的回归系数均未达到统计学显著水平，表明上述收入群体与基准类群体在使用 AI 进行医疗决策的行为上无显著差异。收入为 5000-10000 元群体的回归系数为 0.718，P 值为 0.058，处于边际显著水平，优势比 OR 为 2.05，存在潜在的正向影响趋势。月可支配收入 10000-15000 元群体的回归系数为 2.218，在 0.1% 水平下极显著，且优势比 OR 为 9.193，表明中等偏高收入水平用户更倾向于使用 AI 进行医疗决策。

## 5. 同居亲属

在同居亲属维度的检验中,以同居亲属为子女群体为基准参照组,同居亲属为祖辈与无同居亲属两类群体的回归系数均未达到统计学显著水平,表明上述家庭亲属结构与基准类群体在使用 AI 进行医疗决策的行为上无显著差异。而同居亲属为父母的群体回归系数为 2.679,在 0.1%水平下显著,且优势比 OR 为 13.874,这一结果说明与父母同居的用户更倾向使用 AI 进行医疗决策。

结合各变量结果,我们可以得出,高学历、中等偏高收入、与父母同居的女性学生更倾向于使用 AI 进行医疗决策。

# 六、基于神经网络模型的公众对 AI 医疗使用意愿影响因素分析

尽管上述 Logistic 回归模型成功识别了影响公众使用意愿的显著人口统计学特征，但只基于线性假设的建模逻辑难以充分捕捉信任机制、场景适配与技术感知等多维因子间复杂的非线性交互作用及隐性关联。鉴于公众对 AI 医生的使用意愿是多变量在特定情境下**动态耦合**的结果，可能存在传统线性模型无法量化的阈值效应或**复杂中介路径**，本研究进一步引入**人工神经网络（ANN）模型**，旨在突破线性约束，深度挖掘影响意愿的**非线性驱动机制**。

## （一）模型概述

人工神经网络是模拟生物神经系统信息处理机制的数学模型，通过多层非线性性单元的连接与迭代优化，实现对数据内在特征的自适应提取与复杂映射关系拟合，是深度学习的核心基础架构。本研究采用前馈神经网络，通过输入层接收问卷收集的各类影响因素数据，经由一个或多个隐藏层的非线性变换<sup>[23]</sup>，最终在输出层预测公众的使用意愿（接受/不接受，或意愿强度）。

神经元是神经网络的最小运算单元，整体网络采用层级化前馈结构，信号单向传递无反馈，是最经典的多层感知机（MLP）核心架构，也是各类深度神经网络的基础原型。


单个神经元模拟生物神经元的信号处理逻辑，分为线性加权与非线性激活两步运算，数学表达式为：

$$\begin{cases} z = Wx + b \\ a = \sigma(z) \end{cases} \quad (6)$$

其中， $x$  为输入特征向量， $W$  为权重矩阵， $b$  为偏置项， $z$  为线性加权和， $\sigma(\cdot)$  为非线性激活函数， $a$  为神经元输出。激活函数是引入非线性拟合能力的核心，避免多层线性变换退化为单层线性模型，常用 ReLU、Sigmoid 函数，其中 ReLU 函数  $\text{ReLU}(z) = \max(0, z)$  因计算高效、缓解梯度消失问题，成为主流选择。

该模型的核心价值在于：①识别关键驱动因素：量化各属性（如信任、场景、宣传）对最终使用意愿的影响权重。②揭示非线性关系：捕捉不同因素之间复杂的交互作用，例如“高信任度”与“特定医疗场景”如何共同作用于使用意愿。③预测与分类：基于用户画像，预测其对 AI 医生的接受可能性，为推广 AI 医疗使用提供一定的依据。





(二) 模型建立

1. 数据预处理与变量定义

(1) 因变量（输出层）

公众对使用 AI 大模型（如豆包、千问、Deepseek 等）进行医疗决策的意愿。在问卷的是否愿意题目，将其转化为二分类变量：“非常愿意/比较愿意”编码为 1（接受），“一般/比较不愿意/非常不愿意”编码为 0（不接受）。

(2) 自变量（输入层）

根据问卷结构，将影响因素划分为五个维度，共 22 个指标，如表 23 所示：

表 23 公众对使用 AI 大模型进行医疗决策的影响因素

| 潜在变量 | 观测变量 |                 |
|------|------|-----------------|
|      | 指标编号 | 指标问题            |
| 信任属性 | TRU1 | AI 医疗平台承担决策错误能力 |
|      | TRU2 | AI 医疗决策取代医生诊断能力 |
|      | TRU3 | AI 缺乏仪器做出初步诊断能力 |
|      | TRU4 | AI 医疗平台严格保护隐私能力 |
| 宣传属性 | PRO1 | 社交媒体广告推荐        |
|      | PRO2 | 权威媒体报道推荐        |
|      | PRO3 | 政府推荐            |
|      | PRO4 | 亲友推荐            |
| 场景属性 | SCE1 | 缺乏时间时使用 AI 医疗   |
|      | SCE2 | 日常保健时使用 AI 医疗   |
|      | SCE3 | 突发情况时使用 AI 医疗   |
|      | SCE4 | 敏感疾病时使用 AI 医疗   |
|      | SCE5 | 严重疾病时使用 AI 医疗   |
| 基础属性 | BAS1 | AI 提供简洁界面能力是重要的 |
|      | BAS2 | AI 的多语言识别能力是重要的 |
|      | BAS3 | AI 理解疾病描述能力是重要的 |
|      | BAS4 | AI 做出全面诊断能力是重要的 |
|      | BAS5 | AI 解读体检报告能力是重要的 |
| 用户属性 | USE1 | 基本掌握电子设备的使用     |
|      | USE2 | 能够准确表达生病的症状     |
|      | USE3 | 能够接受使用 AI 医疗    |
|      | USE4 | 能够学会使用电子设备      |

(3) 数据编码

所有分类变量（如性别、职业）均进行独热编码；有序变量（如信任程度、使用意愿）可直接使用原始编码或进行标准化处理。

## 2. 模型结构设计

完整神经网络分为三层结构，包括输入层、隐藏层以及输出层。

①**输入层**：负责接收原始数据，神经元数量与输入特征维度一致，即节点数等于输入变量的总数。②**隐藏层**：为核心特征提取层，可设置单层或多层，一般仅设置 1-2 个隐藏层，每层节点数可通过实验调整，通过权重连接实现非线性特征变换，活函数选用 ReLU 或 Sigmoid。③**输出层**：输出最终预测结果，神经元数量适配任务类型，一般为 1 节点（二分类任务，使用 Sigmoid 激活函数输出概率值）或 5 个节点（多分类任务，使用 Softmax）。④**训练与优化**：采用交叉熵损失函数，使用 Adam 优化器进行训练，划分训练集（70%）和测试集（30%），并通过交叉验证防止过拟合。

其结构图如图 17 所示：




图 17 神经网络模型结构

## （三）模型评价与检验

为了确保模型的有效性和可靠性，我们还需对模型进行评估与检验。本文对神经网络模型做了分类应用，尝试将 22 个变量的输入分为两个类别，而评估分类网络的最简单方法是跟踪被错误分类的训练集数据项的百分比。因此，在通过训练集建立模型后，本文对训练集和验证集误分率都进行了评估，其具体分类结

果见图 18、19 所示:




图 18 训练集分类正确率




图 19 测试集分类正确集

图 18、图 19 显示,深蓝色块的数值分别代表是否愿意使用 AI 大模型两个类别的分类正确率,浅蓝色块则代表误分率。可计算出训练集的分类正确率为 91.60%,测试集的分类正确率为 85.45%,均达到很高的正确率。

此外,我们还绘制了模型的 ROC 曲线图,能较为直观地表示出分类器的性能。坐标 (0,0) 和 (1,1) 连线形成的曲线代表的是一个随机分类器的 ROC 曲线,可以将其作为判断基准。

本文中神经网络模型的训练集和测试集 ROC 曲线如图 20、图 21 所示:






图 20 训练集 ROC 曲线




图 21 验证集 ROC 曲线

由图 20、图 21 可以看出，训练集 ROC 曲线和验证集 ROC 曲线的 AUC 分别达到 0.9638 和 0.9220，其效果远超随机分类器。

综合误分类指标和 ROC 曲线的判断标准，认为训练出的多层前馈神经网络模型对样本的预测能力很强、模型效果好，可用该模型对自变量重要性进行评估。

#### （四）不同因素对公众接受使用 AI 大模型的影响分析

在训练模型时，每获取一个特征列就对其进行随机洗牌，使用模型对其进行预测并得到损失值，每个特征列对应的损失值就是特征的重要性，损失越大，则说明特征对该神经网络模型影响越大。我们利用训练好的神经网络模型，模拟不同因素下公众接受意愿的变化，输出各自变量对于因变量的重要性，得到图 22。




图 22 AI 大模型使用意愿影响因素重要性排序

具体而言，信任属性与场景属性共同构成神经网络模型预测的核心驱动力，

二者在公众决策中形成“安全底线+价值上限”的双重约束机制。**信任属性**在所有因素中占据主要地位，其中“AI 医疗平台承担决策错误能力”（TRU1）以最高权重值 0.2758 成为影响使用意愿的**首要因素**，这直接反映出公众对 AI 应用“责任归属”与“容错机制”的高度关注，这是建立用户信任的基石。在当前技术尚未完全成熟的背景下，公众最关心的并非 AI 是否足够“聪明”，而是当它犯错时由谁来承担责任。若某 AI 误诊导致患者延误治疗，责任应由开发者、医院还是使用者自己承担，目前尚无明确界定，这种不确定性直接抑制了用户的使用意愿。因此建立“可追溯、可问责、可补偿”的责任体系，是打破信任壁垒的第一步。**紧随其后**的是“AI 医疗决策取代医生诊断能力”（TRU2），表明用户不仅关注责任兜底，更看重 AI 自身的“专业硬实力”。这意味着公众期待 AI 不仅能辅助问诊，更要具备独立判断复杂病情的能力。这两点共同说明，要提升公众使用意愿，首要任务是建立明确的责任体系并证明 AI 的专业可靠性。

在信任之外，**场景属性与用户自身能力**同样构成关键制约因素。“突发情况时使用 AI 医疗”（SCE3）排名第二，显示出公众对 AI 在应急或救急场景中的高期望，如夜间高烧等无法及时就医的情境下，AI 需成为第一响应者。这为 AI 的应用落地指明了方向：努力打造“24 小时在线的家庭健康守门人”形象，逐步积累用户信赖。同时“能够准确表达生病的症状”（USE2）进入前五，凸显出人机交互的有效性是使用 AI 的关键门槛。许多中老年用户或非医学背景人群担心自己无法清晰描述症状，导致 AI 给出错误建议。这就要求产品设计必须降低表达门槛，例如可引入语音输入、图像上传等功能，让无法准确用文字描述病情的用户也能顺畅沟通。此外，**基础功能**如“AI 解读体检报告能力”（BASE5）也备受重视，这表明 AI 在提供直观价值方面的表现，是吸引用户的重要抓手。无论是老年人还是年轻人，每年进行体检但看不懂报告的现象普遍存在，AI 若能一键生成通俗易懂的健康解读及改善建议，将成为高频刚需入口。

综上，公众对 AI 医疗的使用意愿主要由信任机制、场景适配性及交互能力三大核心维度驱动。要想提升 AI 使用意愿，需从“**建立责任信任体系、强化应急与专业场景落地、优化人机交互设计**”等多方面协同发力，方能有效地消除用户顾虑，推动 AI 技术从“实验室里的黑科技”走向“老百姓身边的真帮手”，真正实现科技惠民的目标。

## 七、基于结构方程模型的影响公众使用 AI 医疗因素的内在作用机制分析

在前文中我们先通过神经网络模型初步挖掘出场景、信任等核心属性是 AI 医生使用意愿的核心影响因素，但该模型存在“黑箱”局限，无法精准刻画变量间因果路径与传导机制。因此，本研究进一步运用结构方程模型（SEM）量化解析潜变量间影响逻辑，揭示“属性特征-场景认知-公众认知-使用意愿”的完整传导机制，实现从变量核心识别到因果机制解构的深度分析。

### （一）模型选择

结构方程模型（Structural Equation Modeling, SEM）是融合验证性因子分析、路径分析与多元回归分析的现代多元统计方法，突破了传统统计方法单一方程、忽略测量误差的局限，能同时处理潜变量测量误差与变量间复杂因果关系，精准刻画观测变量与潜变量、潜变量与潜变量之间的内在关联，广泛应用于社会科学、医疗健康等领域的理论验证与机制分析<sup>[24]</sup>。

本研究借助 SEM 探究五大外生潜变量对公众 AI 医生公众认知与使用意愿的影响方向、作用强度与传导路径。

### （二）模型构建与运行结果

#### 1. 结构方程模型的基本结构

完整的结构方程模型由测量模型与结构模型两部分构成，分别对应潜变量的测量效度检验与潜变量间因果关系验证，具体公式和含义如下：

$$X = \Lambda_x \xi + \delta \quad (7)$$

$$Y = \Lambda_y \eta + \varepsilon \quad (8)$$

公式（7）是**外生潜变量测量模型**，其中  $X$  是外生观测变量、 $\Lambda_x$  是外生观测变量与外生潜变量之间的因子载荷矩阵、 $\xi$  表示外生潜变量、 $\delta$  表示外生观测变量的测量误差向量。公式（8）是**内生潜变量测量模型**，其中  $Y$  是内生观测变量、 $\Lambda_y$  是内生观测变量与内生潜变量之间的因子载荷矩阵、 $\eta$  表示内生潜变量、 $\varepsilon$  表示内生观测变量的测量误差向量。

$$\eta = B\eta + \Gamma\xi + \zeta \quad (9)$$



公式 (9) 为结构模型，其中  $B$  表示内生潜变量之间的关系矩阵、 $\Gamma$  为外生潜变量与内生潜变量关系矩阵、 $\zeta$  是结构方程残差向量。

## 2. 理论模型的构建

各潜变量与调查问卷中观测变量的对应关系及测量题项设计，均基于医疗 AI 领域相关研究与问卷设计逻辑确定，每个潜变量固定 1 个观测变量的因子载荷为 1，最终得到较合理的观测指标如前文表 23 所示。

基于技术接受模型 (TAM)、信任理论及医疗 AI 领域相关研究假设，本研究设定四大潜变量直接作用于场景属性，然后作用于公众认知，公众认知进一步作为中介变量影响使用意愿。基于此，构建的结构方程模型如图 23 所示。




图 23 结构方程模型图

## 3. 实证结果分析

### (1) 测量模型结果分析：问卷题项的信效度检验

测量模型的核心检验指标包括标准化载荷系数、标准误(S.E.)、临界比(C.R.)、P 值，用于验证观测变量对潜变量的表征能力，估计结果如表 24 所示。

表 24 指标路径系数结果

| 因子               | 变量        | 标准化载荷系数 | 临界比(C.R) | 标准误(S.E) | P 值       |
|------------------|-----------|---------|----------|----------|-----------|
| 信任属性 (TRU)       | TRU1      | 0.852   | -        | -        | -         |
|                  | TRU2      | 0.843   | 24.921   | 0.042    | <0.001*** |
|                  | TRU3      | 0.851   | 25.338   | 0.042    | <0.001*** |
|                  | TRU4      | 0.781   | 22.099   | 0.044    | <0.001*** |
| 宣传属性 (PRO)       | PRO1      | 0.668   | -        | -        | -         |
|                  | PRO2      | 0.914   | 17.693   | 0.069    | <0.001*** |
|                  | PRO3      | 0.856   | 17.403   | 0.071    | <0.001*** |
|                  | PRO4      | 0.626   | 16.901   | 0.051    | <0.001*** |
| 场景属性 (SCE)       | SCE1      | 0.747   | -        | -        | -         |
|                  | SCE2      | 0.733   | 23.318   | 0.041    | <0.001*** |
|                  | SCE3      | 0.634   | 15.287   | 0.064    | <0.001*** |
|                  | SCE4      | 0.635   | 15.313   | 0.064    | <0.001*** |
|                  | SCE5      | 0.506   | 12.022   | 0.072    | <0.001*** |
| 基础属性 (BAS)       | BAS1      | 0.779   | -        | -        | -         |
|                  | BAS2      | 0.894   | 24.249   | 0.048    | <0.001*** |
|                  | BAS3      | 0.932   | 25.648   | 0.049    | <0.001*** |
|                  | BAS4      | 0.876   | 23.599   | 0.048    | <0.001*** |
|                  | BAS5      | 0.888   | 24.027   | 0.048    | <0.001*** |
| 用户属性 (USE)       | USE1      | 0.829   | -        | -        | -         |
|                  | USE2      | 0.790   | 21.403   | 0.041    | <0.001*** |
|                  | USE3      | 0.772   | 20.726   | 0.043    | <0.001*** |
|                  | USE4      | 0.865   | 24.269   | 0.040    | <0.001*** |
| 公众认知 (cognition) | cognition | 0.523   | -        | -        | -         |
| 使用意愿 (Intent)    | Intent1   | 0.615   | -        | -        | -         |

#### 1) 收敛效度分析

以标准化载荷系数、临界比 (C.R.) 为核心指标，检验结果显示问卷信效度良好。可见所有观测变量标准化载荷系数均处于合理区间，且载荷系数统计高度显著，说明观测变量对潜变量的表征能力稳定且有效。

#### 2) 问卷设计合理性分析

其中，基础属性的因子载荷整体表现为最高水平，精准贴合公众对 AI 医生核心技术能力、疾病诊断准确性的关键认知关注点，反映出技术硬实力是公众评判 AI 医生的重要标尺；场景属性中 SCE5（严重疾病时使用 AI 医疗）载荷系数

最低，仅为 0.506，这与当前 AI 医生技术发展阶段相契合，现阶段 AI 医生仍主要聚焦于基础健康咨询、日常保健等简单医疗场景，在严重疾病等复杂医疗场景的应用尚未获得公众认可；公众认知与使用意愿的观测变量载荷系数均处于合理区间，能够有效反映公众对 AI 医生的实际使用倾向与长期接受态度。

综上，本次调研问卷的题项设计能够有效表征各潜变量的核心内涵，为后续结构模型的路径分析与机制探究提供了可靠的测量基础。

## （2）结构模型结果分析：影响机制与假设检验

结构模型的核心检验指标包括非标准化系数、标准误（S.E.）、临界比（C.R./Z 值）、P 值、标准化系数，其中标准化系数直接反映外生潜变量对内生潜变量的影响强度与方向，P 值用于检验路径系数的统计显著性，估计结果如表 25 所示。

表 25 结构模型路径系数估计结果

| 潜变量<br>(自变量)        | → | 显变量<br>(因变量)        | 非标准<br>化系数 | 标准误差  | 临界比<br>(C.R./Z<br>值) | p 值       | 标准化系数 |
|---------------------|---|---------------------|------------|-------|----------------------|-----------|-------|
| 信任属性<br>(TRU)       | → | 场景属性<br>(SCE)       | 0.520      | 0.031 | 16.929               | <0.001*** | 0.682 |
| 基础属性<br>(BAS)       | → | 场景属性<br>(SCE)       | 0.284      | 0.043 | 6.654                | <0.001*** | 0.324 |
| 宣传属性<br>(PRO)       | → | 场景属性<br>(SCE)       | 0.227      | 0.034 | 6.667                | <0.001*** | 0.237 |
| 用户属性<br>(USE)       | → | 场景属性<br>(SCE)       | 0.203      | 0.036 | 5.617                | <0.001*** | 0.262 |
| 场景属性<br>(SCE)       | → | 公众认知<br>(cognition) | 0.759      | 0.061 | 12.440               | <0.001*** | 1.000 |
| 公众认知<br>(cognition) | → | 使用意愿<br>(Intent)    | 0.994      | 0.083 | 11.971               | <0.001*** | 1.000 |

注：\*\*\*、\*\*、\*分别代表 1%、5%、10%的显著性水平

①信任属性、基础属性、宣传属性与用户属性均对场景属性呈现显著正向影响。公众对 AI 医生在隐私保护等方面的信任程度越高，AI 医生在疾病理解与诊断分析等核心技术能力越强，越能提升公众对其场景适配性的认知；同时，来自权威媒体等多元渠道的宣传推广，以及公众自身较高的数字素养与清晰的症状表达能力，也会让公众更认可 AI 医生在各类医疗场景中的应用价值。

②场景属性对公众认知存在高度显著的正向影响，是驱动公众认知的核心因素。AI 医疗的场景适配性、实用性与可及性等场景属性，是公众形成对 AI 医生认知的直接来源：当 AI 医疗能够精准匹配便捷就医、慢病管理、辅助诊断等高



频就医场景，且在实际应用中展现出稳定的性能、明确的价值与清晰的使用边界时，公众会逐步建立起对 AI 医生的正向、清晰认知；反之，若场景适配性不足、应用价值模糊，公众对 AI 医生的认知则会呈现模糊、负面的特征。

③公众认知对使用意愿呈现高度显著的正向影响。当前公众对 AI 医生的公众认知直接决定了其对 AI 医生未来的使用意愿，当下对 AI 医生拥有更高认知的公众，对其未来的技术迭代、场景拓展与应用价值持有极高的积极预期。

### （3）模型检验

模型整体拟合优度用于检验理论模型与实际调研数据的适配程度，是判断模型解释力的重要依据。本研究选取 SEM 模型中最具代表性的卡方自由度比、RMSEA、GFI、AGFI、CFI、TLI 六大拟合指标进行拟合优度检验，得到模型结果见表 26，需判断“AI”医生使用意愿结构方程模型是否在统计意义上成立。

表 26 结构方程模型拟合优度结果

| 拟合指标 | $\chi^2/df$ | RMSEA | GFI   | AGFI  | CFI   | TLI   |
|------|-------------|-------|-------|-------|-------|-------|
| 判断标准 | <5          | <0.10 | >0.80 | >0.80 | >0.90 | >0.90 |
| 值    | 4.992       | 0.090 | 0.829 | 0.817 | 0.917 | 0.900 |

结果显示： $\chi^2/df=4.992$ 、 $RMSEA=0.090$ 、 $GFI=0.829$ 、 $AGFI=0.817$ 、 $CFI=0.917$ 、 $TLI=0.900$ ，各指标均满足判断标准，模型表现优秀。

### （三）模型分析结果解释与发展

本研究以公众对 AI 医生的认知与使用意愿为核心，构建 SEM 模型开展实证分析，揭示其内在影响路径与作用机制，核心结论如下：

**第一**，问卷题项设计贴合公众认知、态度及使用场景，观测变量对潜变量的表征能力稳定有效，量表信效度良好，可精准捕捉公众对 AI 医疗的真实使用意愿与认知倾向。**第二**，信任、基础、宣传、用户四大属性均对场景属性呈现显著正向影响，共同塑造了公众对 AI 医疗场景适配性的认知。场景属性与公众认知、公众认知与使用意愿均呈现显著的正向影响，场景适配性在公众使用 AI 医疗的过程中起到承上启下的关键作用。**第三**，从模型的拟合效果上来看，六大拟合指标均满足学术判断标准，说明模型设定具备较强的理论解释力与实证支撑力，能够有效揭示公众对 AI 医生认知与使用意愿的内在影响机制。

## 八、基于 K-means 的用户特征分析及潜在用户挖掘

前述 Logistic、神经网络模型与 SEM 分别从特征、权重与机理维度构建了完整的分析框架。然而为使研究结论具备实践指导意义，必须将上述显著变量回馈到具象的社会群体中。所以本章最后引入 K-means 聚类算法，结合 PCA 降维、聚类有效性指标及使用意愿数据，将显著的人口特征与心理倾向进行多维整合，最终识别出四类具有显著异质性的用户群体以及核心潜在用户，从而将抽象的实证结论转化为具象的群体管理策略，便于 AI 医疗技术研发公司后期针对不同用户群体进行差异化服务<sup>[25]</sup>。

### （一）K-means 聚类原理

K-means 以簇内误差平方和（SSE）最小化为核心优化目标，SSE 用于衡量簇内数据的紧凑程度，数值越小代表聚类效果越优，其数学表达式为：

$$J(C, \mu) = \sum_{k=1}^K \sum_{x_i \in C_k} \|x_i - \mu_k\|^2 \quad (10)$$

式中  $\|x_i - \mu_k\|^2$  为样本到对应簇质心的平方欧氏距离，算法本质是求解最优簇划分与质心组合，使全局 SSE 达到最小值。通过对目标函数求偏导并令偏导数为 0，推出质心最优更新公式，即质心为簇内样本算术平均值：

$$\mu_k = \frac{1}{|C_k|} \sum_{x_i \in C_k} x_i \quad (11)$$

其中  $|C_k|$  为簇内样本数量，公式(10)是算法迭代更新的核心准则。K-means 采用贪心迭代策略，流程精简为四步：初始化初始质心、样本分配至最近簇、更新簇质心、判断迭代终止条件，直至质心无明显变化或达到最大迭代次数，输出最终聚类结果。

### （二）最佳聚类数 K 的确定

我们通过轮廓系数与 CH 指数双指标评估聚类效果如图 24、图 25 所示。从图中可以看出轮廓系数在  $K=4$  时达到峰值，此时类内紧密性最优，类间分离度最高。而且 CH 分数同样在  $K=4$  时取得最大值，进一步确认  $K=4$  为最佳聚类数。

这两个指标协同验证了聚类结构的稳定性与合理性。




图 24 轮廓系数图




图 25 CH 分数图

由图 26、图 27 可知，通过对原始数据进行 PCA 降维，得出第一主成分（PCA1）解释方差 21.61%，第二主成分（PCA2）解释方差 17.77%，累计解释方差 39.38%。模型在迭代 3 次后收敛，最终形成了 4 个聚类簇，无明显重叠或混淆，这表明该聚类模型能捕捉数据中较显著的结构差异，具备良好的解释力。




图 26 样本 PCA 二维分布散点图




图 27 人群分类结果图

通过 SPSS 统计软件的迭代，迭代历史结果如表 27 所示。

表 27 迭代历史结果

| Iteration History <sup>a</sup> |              |              |           |              |
|--------------------------------|--------------|--------------|-----------|--------------|
| Iteration                      | Cluster 1    | Cluster 2    | Cluster 3 | Cluster 4    |
| 1                              | 4.031614E-01 | 9.500372E-01 | 0.0       | 4.467174E-01 |
| 2                              | 1.110223E-16 | 1.144392E-16 | 0.0       | 1.119401E-16 |
| 3                              | 0.000000E+00 | 0.000000E+00 | 0.0       | 0.000000E+00 |



### （三）人群特征画像

基于基础属性的聚类结果，我们划分出的四类人群如图 28 所示。图中显示，四个人群在“学历”、“职业类型”、“家庭同居对象”、“收入”四个维度上呈现明显的扇形分布差异，说明聚类结果在多维空间上具有良好区分度。




图 28 四类人群基础属性雷达图

### （四）人群分群与 AI 医疗使用意愿的关联性分析

在完成 K-means 聚类并识别出四类差异化人群后，为进一步探究“人群簇”与“AI 医疗决策使用意愿”之间是否存在统计学意义上的关联，本文开展了卡方独立性检验，以验证聚类结果对用户使用意愿的解释力。本文提出以下假设：

原假设 H0：人群簇与 AI 医疗使用意愿无显著关联。

备择假设 H1：人群簇与 AI 医疗使用意愿存在显著关联。

经检验，结果如表 28 所示。本次检验的卡方统计量为 111.105，自由度为 3，P 值为 0.000，远小于显著性水平 0.05，因此拒绝原假设、接受备择假设，表明不同簇的用户在使用 AI 大模型辅助医疗决策的行为倾向上存在本质差异。

表 28 卡方独立性检验结果

| 指标                 | 数值      |
|--------------------|---------|
| 卡方统计量 ( $\chi^2$ ) | 111.105 |
| 自由度 (df)           | 3       |
| P 值 (p-value)      | 0.000   |
| 显著性水平 ( $\alpha$ ) | 0.050   |

#### 2. 检验结果与分析

由于 P 值远小于显著性水平 0.05，因此拒绝原假设，接受备择假设——人群

簇与 AI 医疗使用意愿存在显著关联。这表明不同簇的用户在使用 AI 大模型辅助医疗决策的行为倾向上存在本质差异。

### （五）不同人群 AI 医疗决策使用意愿差异分析

通过如图 29 所示的堆叠柱状图对比四类人群的 AI 医疗使用意愿（意愿=1 表示愿意使用，意愿=0 表示不愿意使用），可发现显著的群体差异。




图 29 不同人群 AI 医疗决策使用意愿占比

#### 1.高学历依赖型（人群 1）

这部分人群作为刚步入社会的高学历人群，其 AI 医疗决策使用意愿为 65.8%，在四类群体中位列第二。这一结果看似与“依赖原生家庭”的特征存在矛盾，实则体现了该群体的双重属性。一方面，高学历背景使这类人群具备较强的数字化素养，愿意在轻量健康场景中尝试使用；另一方面，他们信息获取能力较强，在非紧急医疗决策中倾向于选择智能化工具。不过由于经济未独立，这类人群的医疗决策仍受家庭长辈影响，所以表现为“愿意尝试但不会深度依赖”的特征。

#### 2.高收入家庭支柱型（人群 2）

这类人群作为职场稳定、收入最高的家庭经济支柱，其 AI 医疗使用意愿达到四类人群中的峰值 76.3%，是 AI 医疗的核心高意愿用户。该群体的高意愿源于双重核心驱动：一是经济基础与职业稳定性使这类人群具备尝试新型医疗技术的支付能力，对 AI 医疗提升就医效率的价值有清晰认知；二是“家庭支柱”的角色使这类人群承担着家庭成员健康管理责任，他们大多数认可 AI 医疗在家庭健康监测、辅助诊断中的实用价值。同时较高的社会阅历使该类人群对新技术的包容度更高，因此成为使用意愿最强烈的群体。

### 3.高学历独立独居型（人群3）

这类人群作为高学历、独居且生活高度独立的群体，其 AI 医疗使用意愿处于中间水平 50.0%，呈现出“意愿与抗拒各占一半”的明显分化特征。该群体的态度矛盾性源于其生活状态与认知特点。这类人群对便捷医疗服务有较强需求，比较认可 AI 医疗在无人协助场景下的实用价值。但是该群体对技术可靠性、数据隐私安全的敏感度较高，部分人因担心 AI 诊断误差、信息泄露而保持谨慎态度，不愿将核心医疗决策交给 AI 工具，因此使用意愿表现为中等水平。

### 4.家庭核心型家长（人群4）

这部分人群作为以子女为生活中心的家庭核心型家长，他们的 AI 医疗使用意愿在四类群体中处于最低水平，近 70.0%的受访者表现出明确的使用抗拒。可能因为该群体肩负着子女与全家的健康责任，对医疗决策的安全性、准确性要求极高，尤其担心 AI 诊断的误差风险会影响家人健康。而且这类人群的传统医疗观念根深蒂固，更信任线下专业医疗机构与医生的面对面诊断，对智能化医疗工具的信任度较低，因此成为 AI 医疗渗透难度最大的群体。

## （六）不同用户群体对五维属性的重视程度

各个群体对不同属性的重视程度如图 30 所示（5 分制：1=非常不重视，5=非常重视）。不同人群对这五个属性各个指标的重视度评分见附录五。




图 30 不同人群在 AI 大模型各属性上的平均分对比

**高学历依赖型**对用户属性的重视程度最高，得分均值达到 3.51，其次为信任属性（3.40）和场景属性（3.40）。该类群体对基础属性和宣传属性的关注度相对较低，表明他们在使用 AI 大模型时更关注产品的责任承担能力和以及个性化体验基础体验，对外部宣传和基础体验的依赖程度较低。



**高收入家庭支柱人群**对用户属性和场景属性的重视程度较为突出，平均得分分别达到 3.58 和 3.46。相比之下，该类群体对信任属性的重视程度最低，只有 3.35。说明这类更关注 AI 大模型在实际应用场景中的适配性以及个性化体验，对产品的责任承担能力的敏感度较弱。

**高学历独立独居**在各属性上的重视程度分布较为分散，其中宣传属性(4.00)显著高于其他维度。该类群体对用户属性的关注度处于较低水平(2.83)，这表明该类人群在使用 AI 大模型时对品牌声誉以及外部宣传信息较为敏感。

**家庭核心型家长**对信任属性的重视程度最高，达到 3.41，显著高于其他群体。同时该类群体对基础属性的重视程度也相对较高(3.38)。说明他们在选择 AI 时更倾向于基于其本身的可靠性和基础功能做出判断，而非受外部宣传影响。

总体来看，四类用户群体在五维属性上的重视程度呈现明显的分化特征。这说明 AI 医疗技术在面向不同用户群体时，需针对其属性偏好进行差异化设计。

### (七) 最具潜力的核心用户群体

综合各项属性重视程度来看，**高学历独立独居型人群**（人群 3）是市场推广中值得优先培育的**核心潜在用户**，是产品优化的重点服务对象。

第一，这类人群在信任、场景和基础属性上均远高于其他三组人群，说明他们对 AI 医疗产品的可靠性、适用场景多样性以及功能稳定性有着极高的要求。这类用户找到能够满足其严苛标准的产品，往往会产生较强的使用粘性和忠诚度。

第二，该人群对**宣传属性**的重视程度明显高于其他群体，意味着他们更容易被有效的宣传推广所触达。

第三，这部分人群对**用户属性**的重视程度较低，用户属性包含电子设备的使用能力、接受能力、表达能力和学习能力——该群体对这些能力重视程度低，恰恰说明他们自身已具备较强的数字素养和技术接受能力，不需要产品在用户能力适配方面投入过多资源，反而更关注产品本身是否足够可靠、智能和易用。

## 九、结论与展望

### （一）结论

本文通过研究主要得出以下结论：

#### 1. 公众态度：支持但审慎，政府推荐是关键驱动力之一

调查显示，广州市公众对 AI 医疗的了解尚不全面，但近 70.4% 的人表示对 AI 医疗的改良升级持支持态度。AI 医疗已开始融入部分人群的日常生活，使用场景日趋多元化。然而公众在认可其便捷性与及时性的同时，对数据安全、责任归属等问题仍存顾虑，呈现出“支持但审慎”的复杂心态。在诸多影响使用意愿的因素中，政府推荐的影响力显著高于其他宣传渠道，表明公众对政府政策引导具有高度信任，因此通过政策引导能增强公众对 AI 医疗的信任基础。

#### 2. 影响机制：五维属性共同驱动，场景属性发挥中介作用

公众对 AI 医疗的使用意愿并非由单一因素决定，而是受到信任属性、场景属性、基础属性、用户属性和宣传属性的综合影响。其中通过构建神经网络模型发现，平台承担决策错误的的能力、AI 医疗决策代替医生的诊断能力、敏感疾病的诊断、用户对 AI 的接受能力、AI 解读报告的能力是影响用户决策的关键指标。进一步分析发现，结构方程模型的结果显示，信任、基础、用户、宣传四个属性均通过影响场景属性间接作用于使用意愿，场景属性在其中发挥核心中介作用。这意味着公众对 AI 医疗的接受与否，最终取决于其能否在具体医疗场景中切实满足用户需求。

#### 3. 用户画像：群体分化显著，高学历独立独居型人群是核心潜力用户

通过 Logistics 回归发现，不同用户在年龄、学历、收入、家庭结构等方面存在明显差异。具体而言，高学历、中等偏高收入、与父母同居的女性学生更倾向于使用 AI 进行医疗决策。通过聚类分析，本研究进一步将用户划分为四类群体：高学历依赖型、高收入家庭支柱人群、高学历独立独居型、家庭核心型家长。其中，高学历独立独居型人群最具潜力，该类群体在信任属性、场景属性、基础属性上的重视程度均远高于其他群体，对产品可靠性要求较高。他们自身数字素养较强，能够快速适应 AI 医疗产品，一旦产品满足其严苛标准，将具备较强的使用粘性与口碑传播潜力，是市场推广中值得优先培育的核心潜在用户。

## （二）对策建议

### 1. 强化政府权威引导，构建信任驱动型宣传体系

通过描述性统计分析发现政府推荐是影响用户使用意愿的关键因素。应充分发挥政府的公信力优势，构建以政府为主导的权威宣传矩阵。一是要联合媒体、社区以及医疗机构开展 AI 医疗科普宣传活动，通过政策解读等形式，向公众传递 AI 医疗的核心价值与风险边界。二是针对公众普遍关心的数据安全与责任归属问题，政府部门应主动发声，通过发布白皮书、设立咨询热线等方式，彰显政府对公民健康信息安全的重视，从而增强公众对 AI 医疗的信任与使用意愿。

### 2. 聚焦场景属性中介作用，以真实需求撬动使用意愿

研究发现，信任、基础、用户、宣传四个属性均通过场景属性间接影响使用意愿，场景属性发挥核心中介作用。因此，推动 AI 医疗普及的关键在于让用户在真实场景中感受到实用价值。第一，要优先布局高频刚需场景，如慢性病管理、日常健康咨询、体检报告解读等，让 AI 医疗从“能用”转向“好用”。第二，要推动 AI 医疗与现有医疗服务体系深度融合，在社区医院、药店、体检中心等场所设置 AI 辅助诊疗终端，让公众在熟悉的医疗场景中自然接触并接受 AI 医疗。第三是针对高学历独立独居型等核心潜力用户，重点打造个性化健康管理等深度场景应用，以优质场景体验转化为持续使用意愿。

### 3. 实施差异化产品策略，精准对接核心潜力用户

由于不同用户群体在属性偏好上存在显著差异，应采取差异化产品设计与推广策略。第一，针对高学历独立独居型这一核心潜力用户群体，应重点打造“高可靠、高智能、高定制”的产品体验。第二，针对高收入家庭支柱型人群，应该侧重 AI 大模型在实际应用场景中的适配性以及个性化体验。第三，针对高学历依赖型人群，应侧重个性化体验，提供高度自定义功能与清晰的责任边界说明。第四，针对家庭核心型家长，应强化产品的安全性与稳定性，通过家长社群口碑与教育机构合作建立信任。

## （三）展望

本研究通过多维数据与混合研究方法揭示了公众对“AI 医生”的认知差异与使用意愿影响机制，为 AI 医疗的普及提供了初步的实证依据。然而，研究仍存在一定局限性，未来可从以下方向进一步深化：

### 1. 理论拓展与模型优化



当前研究基于现有理论框架构建模型较单一分析得出结论，未来可以尝试融合心理学、伦理学等多学科视角，开发出更具解释力的“AI 医疗使用意愿”整合模型。同时，可以尝试引入因果推断模型或动态演化算法，解析公众态度随时间变化的复杂机制，从而更精准地得出其对“AI 医生”的看法。

## 2. 实践应用与价值转化

基于研究发现，可以更针对性地设计 AI 医疗推广策略，例如：针对“风险规避型”群体加强技术安全性宣传，针对“场景依赖型”群体开发差异化服务场景。同时，建议医疗机构与科技企业合作构建“AI 医生”服务评价体系，通过用户反馈动态优化模型性能，形成“研究-实践-反馈”的良性循环。

## 3. 前沿技术融合探索

随着生成式 AI、多模态交互等技术的突破，未来可研究新一代 AI 模型在医疗场景中的使用意愿变化，例如结合具身智能的 AI 医生能否通过情感共鸣提升用户信任度等，此类探索将在一定程度上促进拓展 AI 医疗的人本化边界。

## 参考文献

- [1] 赵丹娜.公立医院医务人员对人工智能医疗应用及其伦理问题的认知、态度和行为研究[D].安徽医科大学,2024.
- [2] 刘伶俐,贺一墨,刘祥德.患者对人工智能医疗的认知及信任度调查[J].中国医学伦理学,2019,32(08):986-990.
- [3] 徐志杰,蔡博宇,常富强,等.互联网用户对在线医疗服务的隐私敏感性及安全认知状况的调查与伦理对策[J].中国医学伦理学,2017,30(01):9-14.
- [4] 徐汉辉.基于“医患信任”理论的医疗AI可信度问题的探讨[J].工程研究-跨学科视野中的工程,2020,12(03):252-259.
- [5] 雷禹,胡圆圆.从隐私悖论到理性权衡:生成式AI医疗应用的隐私担忧与情境治理[J/OL].新媒体与社会,1-17[2026-03-19].<https://link.cnki.net/urlid/CN.20260312.1801.019>.
- [6] 郑艺,林仲轩.“信AI还是信医生”:低风险健康情境下的信源身份、信任与采纳意图[J].暨南学报(哲学社会科学版),2025,47(11):32-48.
- [7] 傅苏颖.AI医疗服务大模型迎来风口[N].中国证券报,2023-06-08(A06).
- [8] 邓婕.“AI+医疗”驶入发展快车道[N].经济参考报,2024-07-10(006).
- [9] 闫海荣,江瑞,张学工,等.DeepSeek与医学大语言模型:技术创新与医疗服务模式重构[J].医学信息学杂志,2025,46(02):1-7+13.
- [10] 严雪华,王宗水,葛新权.基于ChatGPT的我国数字医疗发展前景、挑战和策略分析[J].科学与管理,2024,44(05):34-40.
- [11] 顾锡新.医疗AI大模型的发展与产业应用研究[J].华东科技,2025,(08):60-63.
- [12] 孟晓宇,王忠民,景慎旗,等.医疗人工智能的发展与挑战[J].中国数字医学,2019,14(03):15-17.
- [13] 周姝芸,侯荷若雪.AI健康,开出更多“良方”[N].人民日报海外版,2026-03-16(008).
- [14] 卢旋.基于UTAUT模型的移动医疗用户使用意愿研究[D].贵州大学,2022.
- [15] 侯文杰,朱瑞,王凌梦,等.技术焦虑对老年人健康促进行为的影响:健康信息素养的中介与自我效能的调节作用[J].医学信息学杂志,2025,46(12):27-33.

- [16] 胡文轩,张木雨,司广森,等.数据透明度对患者医疗生成式人工智能使用意愿的“双刃剑”影响研究[J/OL].系统管理学报,1-18[2026-03-22].<https://link.cnki.net/urlid/31.1977.n.20260310.1738.002>.
- [17] 陈志锋.基于慢病感知的智能穿戴设备持续使用意愿及行为研究[D].华中科技大学,2023.
- [18] 周中允,杨艳丽,向宇婧,等.影响移动医疗App用户体验及行为的机制研究[J].信息系统学报,2025,(01):35-50.
- [19] 杜壮.AI诊疗超过医生,算力、算法和数据缺一不可[N].中国经济导报,2026-03-12(003).
- [20] 李喆.AI在医疗中的应用[J].通信企业管理,2023,(10):58-61.
- [21] 孔祥溢,王任直.人工智能及在医疗领域的应用[J].医学信息学杂志,2016,37(1):2-5.
- [22] 李轩,徐芳.农村女性担任村干部的影响因素调查——基于计划行为理论对Z县调查数据二元Logistic回归分析[J].中南农业科技,2025,46(S1):139-144.
- [23] 庄苏,申珂,应婷婷,等.长三角区域新质生产力对工业创新投入影响研究——基于多元线性回归与神经网络模型[J].现代工业经济和信息化,2025,15(12):1-5.DOI:10.16525/j.cnki.14-1362/n.2025.12.001.
- [24] 薛娇,高海燕.贝叶斯分位数结构方程模型的变分近似推断[J].统计与决策,2024,40(24):29-35.DOI:10.13546/j.cnki.tjyjc.2024.24.005.
- [25] 贾琳,刘海峰,王新.基于K-means和XGBoost的电信运营用户套餐选择预测方法[J].计算机应用,2025,45(S2):131-136.